2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Cátedra: Fundamentos de la Ciencia de Datos

Integrantes:

Coronado, M. del Rosario

Delorenzi, Valentin

Migueltorena, Rocio

Ayudante asignado:

Santiago Vitale

Grupo: 07

1. Introducción **4**
1.1 Contexto 4
1.2 Vocabulario Base de Automóviles y Protocolos de Ensayo 4
1.3 Origen, Utilidad y Estructura del Conjunto de Datos 6
1.3.1 Columnas irrelevantes (Seccion 1.1.1 entrega.ipynb) 7
1.3.2 Redundancia de variables (Sección 1.1.2 entrega.ipynb) 7
1.3.2 Valores nulos estructurales (Missing Not At Random - MNAR): 7
1.4 Organización del trabajo 9
2. Análisis exploratorio de los datos **10**
2.1 Estructura y Taxonomía de Atributos 10
Identificación del vehículo 10
Características del vehículo y motor 10
Transmisión y tracción 10
Información del ensayo 11
Tipo de combustible 11
Economía de combustible 11
Variables ADFE (Analytically Derived FE) 11
Variables de dinamómetro y road load 11
Postratamiento de emisiones 12
Variables de averaging 12
Variable especial 12
2.2 Análisis Univariado: 12
2.3 Análisis Bivariado: 12
2.3 Análisis Multivariado: 12
2.4 Discrepancia en hipotesis urbanas 13
3. Hipótesis **13**
3.1. Hipótesis 1 propuesta por la cátedra 13
3.1.1. "La mayoría de las configuraciones de vehículos a combustión alcanzan al menos 25 MPG de economía de combustible en condiciones de conducción urbana." 13
(Sección 4.1 entrega.ipynb) 13
3.1.2. Estrategia de abordaje 13
Entendiendo un poco más el dominio 15
3.1.3. Resultados obtenidos y discusión 15
3.2. Hipótesis 2 propuesta por la cátedra: 16
3.2.1. “En vehículos de combustión, la economía de combustible difiere según el sistema de tracción del auto”. 16
3.2.2. Estrategia de abordaje 17
3.2.3. Resultados obtenidos y discusión 22
3.3. Hipótesis 3 propuesta por la cátedra: 24
3.3.1 “Entre vehículos a combustión, las características técnicas del vehículo (peso, potencia, cilindrada, número de cilindros, transmisión y sistema de tracción) se encuentran asociadas conjuntamente con su eficiencia de combustible urbana.” 24
3.3.2 Definición de la hipótesis 24
3.3.3. Estrategia de abordaje 24
3.3.4. Resultados obtenidos y discusión 25
3.4 Hipótesis univariada propia: 32
3.4.1. “En los autos de combustión testeados por EPA en 2025, presentan una mediana de Axle ratio menor a 3.73” 32

3.4.2. Estrategia de abordaje 33
3.4.3. Resultados obtenidos y discusión 33
3.5. Hipótesis 2: bivariada propia 35
3.5.1. “El nivel de emisión de CO2 en autos que utilizan combustión en ciclos urbanos, difiere según el tipo de transmisión utilizado.” 35
3.6. Hipótesis 3 : multivariada propia 39
3.6.1. "En vehículos a combustión en ciclo urbano, la potencia del motor determina el perfil multidimensional de emisiones de gases contaminantes (C02, CO, THC, CH4), permitiendo segmentar el impacto ambiental de la flota según su número de cilindros." 39
3.6.2. Estrategia de abordaje 39
3.6.5 Consideraciones Finales 44
4. Conclusiones **44**
4.1 Perfil general 44
4.2 Transmisión y tracción. 45
4.3 Potencia, emisiones y eficiencia. 45
Referencias **46**

1. Introducción

1.1 Contexto

El control de emisiones contaminantes y la economía de combustible son pilares fundamentales para la regulación ambiental y energética en toda la industria automotriz. En Estados Unidos existe la Agencia de Protección Ambiental, conocida como EPA. La cual audita y certifica el desempeño ecológico de los vehículos que salen al mercado.
Los datos obtenidos de estos ensayos de laboratorio son usados para etiquetar e informar a los consumidores y ayudarlos a comparar modelos, basados en la Guía de la Economía del Combustible del Departamento de Energía (DOE); también ayudan a el Departamento de Transporte (DOT) para garantizar el cumplimiento de las normas de eficiencia corporativa (CAFE) y al Servicio de Impuestos Internos (IRS) para fiscalizar penalizaciones por alto consumo (Gas Guzzler Tax).

Comprender la relación entre las características técnicas de los motores (potencia, cilindrada, marchas) y su rendimiento en condiciones de manejo es crucial para evaluar si las flotas actuales logran equilibrar el rendimiento mecánico con la sustentabilidad ambiental.

1.2 Vocabulario Base de Automóviles y Protocolos de Ensayo

Para facilitar la interpretación de los datos a lo largo del informe les compartimos un poco de conocimiento fundamental respecto al funcionamiento de un automóvil, lo cual fue también una barrera para nosotros teniendo que investigar y aprender cómo funciona la mecánica en ellos y las metodologías en la realización de ensayos.

- **MPG** (Miles Per Gallon / Millas por Galón): Unidad para medir cuántas millas puede recorrer un vehículo consumiendo 1 galón de combustible.
  Relacionado con ciclos de prueba en el dataset:
- **Categorías** ciclos de prueba en el dataset
  - **CITY FE = ciudad** mide el rendimiento en condiciones urbanas, donde se frena más, se acelera desde cero, hay tráfico y marchas lentas. Donde suele dar un **MPG más bajo.**
  - **HWY FE = ruta** mide el rendimiento a velocidades constantes y elevadas, donde hay pocas frenadas. Donde el **MPG es más ALTO** debido a la inercia (el vehículo sigue el movimiento que lleva y no hay que acelerarlo, sino solo ir manteniendo la velocidad, entonces cuesta menos).
  - **COMB FE = combinado** un promedio ponderado entre ciudad y ruta para representar el uso promedio de un conductor típico.

- **Cilindrada**: Es el volumen total acumulado en el interior de todos los cilindros del motor. Medida en Litros o Pulgadas cúbicas.

- ➢ Implica que en motores más grandes (**mayor cilindrada**) pueden tener más aire y combustible dentro, genera más fuerza, pero también generalmente **consumen más combustible**.

❖ **Número de cilindros :** son los “tubos” dentro del motor donde explota la mezcla de aire y combustible para mover los pistones. Toma valores: 3, 4, 6, 8, o 12 cilindros.

- ➢ Implica que ante más cilindros suelen brindar una entrega de potencia más suave y refinada pero aumentan la fricción interna y el **consumo de combustible**.

❖ **Potencia nominal (Rated Horsepower / HP):** los **caballos de fuerza** que genera el motor a su **MÁX rendimiento**.

- ➢ Implica que es la **capacidad** del auto para **acelerar** rápido o alcanzar velocidades altas.
- ➢ A mayor cantidad de HP, el motor requiere quemar más energía, lo que reduce la eficiencia de combustible en condiciones de exigencia.

❖ **Tipos de transmisión (Tested Transmission Type):**

- ➢ **Automática**: el vehículo pasa los cambios solo con un sistema mecánico/hidráulico o eléctrico.
- ➢ **Manual:** el cambio lo efectúa el conductor usando el embrague y mueva la palanca de cambios para cambiar la marcha.
- ➢ **Continuamente variable:** no tiene engranajes fijos (1era, 2da, 3era..) sino un sistema de poleas que varía infinitamente las relaciones, mantiene el motor siempre en el punto óptimo de consumo, resultando muy eficiente en la ciudad.
- ➢ **semi automática / doble embrague:** combina la velocidad y precisión de una caja manual con la comodidad de pasar cambios automáticamente o con paletas en el volante.

❖ **Transmisión de fuerza (Drive system)**: Para indicar a cuales de las 4 ruedas les envía fuerza el motor.

- ➢ **Tracción delantera (FWD)** La fuerza va solo a las dos de adelante. El sistema es el más liviano, económico de fabricar y **eficiente energéticamente**.
- ➢ **Tracción trasera (RWD)** La fuerza va solo a las ruedas de atrás. Es común en deportivos y camionetas pesadas. **suele perder más energía** por la longitud del eje de transmisión.
- ➢ **Tracción Integral / Total (AWD):** La fuerza va a las 4 ruedas (de forma permanente o demandada) para dar mejor agarre en todo terreno, nieve, barro, curvas. Al tener más ejes, engranajes y componentes pesados, genera más fricción mecánica, lo que suele **reducir la eficiencia(MGP)** respecto a modelos **FWD** (delantera).

Parámetros mecánicos de transmisión y ensayo

- ➢ **Relación de Eje / Relación del Diferencial** (Axle Ratio): relación entre las vueltas que da el eje de **transmisión** (el que viene de la caja de cambios) y las vueltas que completan las **ruedas**.

Se expresa como un número (x = 3.55, 4.10, 2.73 …). tiene que dar **X vueltas** para que la rueda dé **1 sola vuelta completa**.

Impacto en el MPG: un Axle Ratio más bajo genera mayor MPG (Ahorra combustible) ya que al girar el motor a menos revoluciones por minuto para mantener una velocidad en ruta, gasta menos. Por otro lado un Axle Ratio más alto implica menor MPG (Mayor consumo) donde el motor va girando a más revoluciones a la misma velocidad, quemando más combustible.

- **Dinamómetro:** simula la pista real para hacer pruebas, los rodillos hacen de " caminadora" para el vehículo.
- **Coeficientes**: que simulan la resistencia aerodinámica y de rodadura.
  - **Coeficiente A:** Simula la fricción del rodamiento de los neumáticos contra el suelo.
  - **Coeficiente B:** Simula las pérdidas de fricción mecánica de los componentes internos.
  - **Coeficiente C:** Simula la resistencia aerodinámica (cómo frena el aire al vehículo cuando aumenta la velocidad).

El investigar en profundidad el funcionamiento interno nos facilitó comprender problemas que encontramos al trabajar con los datos. Recalcando la importancia de embeberse en el contexto ya que así los motivos, ideas o respuestas aparecen más rápido.

1.3 Origen, Utilidad y Estructura del Conjunto de Datos

El conjunto de datos analizado corresponde a la lista oficial de pruebas de vehículos EPA Fuel Economy - Model Year 2025 ("*25-testcar-2026-01-21.xlsx*"). La base contaba originalmente con 4.287 registros y 67 atributos.

Los datos provienen de mediciones estandarizadas realizadas en el **National Vehicle and Fuel Emissions Laboratory de la EPA** en Ann Arbor (Michigan) y de pruebas certificadas por los propios fabricantes bajo supervisión federal. Donde cada fila representa una configuración técnica específica de un vehículo sometida a un ensayo particular.

Durante el análisis exploratorio preliminar se identificaron varias situaciones principales en la calidad y estructura de los datos detalladas a continuación. Cabe mencionar que se verificó en la Sección 3 en entrega.ipynb la presencia de duplicados pero no había casos, pero tuvimos muy en cuenta en nuestros análisis qué mismas configuraciones de autos eran repetidas para varios tests, cuidando no trabajar sobre hipótesis específicas de configuraciones tales como "Marcas o fabricantes más populares o con mas modelos en el mercado", que hubieran requerido un filtrado de duplicados.

1.3.1 Columnas irrelevantes *(Seccion 1.1.1 entrega.ipynb)*

Aquellas columnas que no aportan información nueva fueron eliminadas del dataset tales como “Model Year”, ya que todo el análisis es del mismo año (2025), y la columna “FE UNIT” que poseía el valor “MPG” en todos su registros, manteniendo la constancia que las columnas “RND_ADJ_FE” y las FE_BAG estan medidas en esa unidad.

1.3.2 Redundancia de variables *(Sección 1.1.2 entrega.ipynb)*

Se detectó la presencia simultánea de columnas codificadas y descriptivas que explicaban exactamente lo mismo (relación 1:1). Para evitar colinealidad y simplificar el análisis sin perder información, se eliminaron en algunos casos las columnas de código conservando sus versiones descriptivas legibles y en otros casos se optó por mantener el Código, el cual resultaba suficientemente informativo de por sí.

conservando el código (legibilidad)

- 'Transmission Overdrive Desc',

conservando la descripción (legibilidad)

- 'Shift Indicator Light Use Cd',
- 'Test Procedure Cd',
- 'Test Fuel Type Cd',
- 'Aftertreatment Device Cd',
- 'Averaging Method Cd',
- ‘Tested Transmission Type Code’,
- ‘Drive System Code’,

Para verificar que estábamos hablando de una relación 1:1 realizamos un crosstable para cada par, confirmando que por ejemplo, para cada “Tested Transmission Type” corresponde unívocamente a un “Tested Transmission Type Code”.

Tested Transmission Type Code	A	AM	AMS	CVT	M	OT	SA	SCV
Tested Transmission Type								
Automated Manual	0	52	0	0	0	0	0	0
Automated Manual- Selectable (e.g. Automated Manual with paddles)	0	0	485	0	0	0	0	0
Automatic	1639	0	0	0	0	0	0	0
Continuously Variable	0	0	0	490	0	0	0	0
Manual	0	0	0	0	128	0	0	0
Other	0	0	0	0	0	102	0	0
Selectable Continuously Variable (e.g. CVT with paddles)	0	0	0	0	0	0	0	171
Semi-Automatic	0	0	0	0	0	0	1220	0

Ejemplo de los crosstable realizados en el Jupyter Notebook entregado incluimos algunos casos a modo de ejemplo (Sección 1.1.2 entrega.ipynb)

1.3.2 Valores nulos estructurales (Missing Not At Random - MNAR):

Existen columnas con un alto porcentaje de faltantes que responden al diseño de las pruebas o al tipo de motorización. Por ejemplo, las variables de cilindros o postratamiento de escape son nulas en vehículos 100% eléctricos o de hidrógeno al carecer de motor térmico, mientras que la economía de combustible oficial (RND_ADJ_FE) figura en blanco en ensayos exclusivos de emisiones o en pruebas de descarga de batería (CD). La decisión metodológica fue mantenerlos

documentados y filtrar las filas según la necesidad de cada hipótesis, sin imputar datos que alterarían los promedios reales.

	Nulos	Porcentaje (%)
Averaging Group ID	4212	98.25
Averaging Weighting Factor	4212	98.25
ADFE Total Road Load HP	4075	95.05
ADFE N/V Ratio	4075	95.05
ADFE Equiv. Test Weight (lbs.)	4075	95.05
ADFE Test Number	4075	95.05
FE Bag 4	3899	90.95
PM (g/mi)	3898	90.93
FE Bag 3	2834	66.11
FE Bag 2	2423	56.52
FE Bag 1	2423	56.52
N2O (g/mi)	2063	48.12
CH4 (g/mi)	1122	26.17
THC (g/mi)	958	22.35
NOx (g/mi)	885	20.64
CO (g/mi)	884	20.62
CO2 (g/mi)	724	16.89
DT-Inertia Work Ratio Rating	695	16.21
DT-Energy Economy Rating	695	16.21
DT-Absolute Speed Change Ratg	695	16.21
# of Cylinders and Rotors	670	15.63
Aftertreatment Device Cd	670	15.63
Aftertreatment Device Desc	670	15.63
RND_ADJ_FE	221	5.16

Porcentaje de nulos (NaN) observados en el dataset. (Sección 2 entrega.ipynb)

En la “seccion 2.2 de entrega.ipynb“ se detallaron minuciosamente la existencia de los nulos para cada atributo observado, colocandolo en el contexto real del dataset. Inclumos en el informe solo el de “RND_ADJ_FE” debido a su importancia a lo largo del informe.

➢ “RND_ADJ_FE “

Rounded Adjusted Fuel Economy (economía de combustible ajustada y redondeada oficial de la prueba, medida en MPG). Analicemos los diversos motivos que conllevan a la presencia de nulos en el atributo:

❖ Ensayos Exclusivos de Medición de Emisiones (Pruebas FTP específicas)

Ensayos como Cold CO (emisiones en frío) y CVS 75 tienen como objetivo exclusivo cuantificar el volumen de gases contaminantes liberados en condiciones críticas o evaluar el sistema de escape. En estas pasadas de laboratorio no se certifica el rendimiento oficial de combustible, por lo que el campo queda deliberadamente en blanco.

❖ Ciclos Complementarios de Alta Exigencia (SC03 y US06)

Las pruebas SC03 (manejo con aire acondicionado al máximo) y US06 (conducción agresiva a alta velocidad) miden el comportamiento del motor bajo condiciones extremas.

La EPA utiliza estos resultados para calcular promedios ponderados globales y no para asignar un valor individual de "*RND_ADJ_FE"* en esa fila puntual.

- Pruebas en Modo Eléctrico / Híbrido (Charge Depleting - CD)

  En vehículos híbridos enchufables evaluados en fase de descarga de batería, un protocolo de prueba diseñado exclusivamente para vehículos híbridos enchufables (PHEV) usando incluso utilizando gasolina como combustible de respaldo, la eficiencia se mide bajo métricas eléctricas especiales y no en la columna convencional de MPG.

- Derivación Analítica de Consumo (ADFE)

  En ciertos vehículos, el consumo de combustible no se mide físicamente sobre los rodillos del dinamómetro, sino que se calcula mediante fórmulas analíticas. En estos casos, la información se vuelca en las variables específicas de derivación (ADFE), dejando nula la columna de medición directa tradicional.

1.4 Organización del trabajo

El informe se estructura en las siguientes secciones principales para guiar la lectura y vincular los hallazgos con el código desarrollado

- Sección 1: Limpieza del dataset
- Sección 2: Nulos
- Sección 3: Control de Registros Duplicados
- Sección 4: Hipótesis planteadas por la cátedra
- Sección 5: Hipótesis propias

2. Análisis exploratorio de los datos

2.1 Estructura y Taxonomía de Atributos

El conjunto de datos original cuenta con 4.287 registros y 67 columnas. Una configuración única queda identificada por la combinación de "**Veh Mfr Code + Test Vehicle ID + Test Veh Configuration #"**. Debido a esto, un mismo modelo puede figurar en múltiples filas si fue evaluado en distintos ciclos de conducción (por ejemplo, en ciclo urbano FTP, en ruta HWY o en pruebas de emisiones en frío)

Para formalizar el trabajo inicial (desarrollado en la Sección 1 y 2 en "entrega.ipynb"), Realizamos pruebas sobre el dataset tales como *.info(), .describe(), .isna(), .value_counts()* sobre cada columna y además de otras funciones propias de *pandas* para poder ver los valores que tomaban los datos y conocerlos para así poder clasificar las variables según su tipo de dato estadístico, diferenciando entre atributos cualitativos y cuantitativos. (Agrupadas según criterio planteado por la catedra)

Identificación del vehículo

- Model Year : CUANTITATIVA DISCRETA
- Vehicle Manufacturer Name : CUALITATIVA NOMINAL
- Veh Mfr Code: CUALITATIVA NOMINAL
- Represented Test Veh Make : CUALITATIVA NOMINAL
- Represented Test Veh Model : CUALITATIVA NOMINAL
- Test Vehicle ID : CUALITATIVA NOMINAL
- Test Veh Configuration # : CUALITATIVA NOMINAL
- Actual Tested Testgroup : CUALITATIVA NOMINAL

Características del vehículo y motor

- Vehicle Type : CUALITATIVA NOMINAL
- Test Veh Displacement (L) : CUANTITATIVA CONTINUA
- Rated Horsepower: CUANTITATIVA CONTINUA
- # of Cylinders and Rotors : CUANTITATIVA DISCRETA
- Engine Code : CUALITATIVA NOMINAL

Transmisión y tracción

- Tested Transmission Type Code : CUALITATIVA NOMINAL
- Tested Transmission Type : CUALITATIVA NOMINAL
- # of Gears : CUANTITATIVA DISCRETA
- Transmission Lockup? : CUALITATIVA NOMINAL BINARIA (DICOTÓMICA)
- Drive System Code : CUALITATIVA NOMINAL
- Drive System Description : CUALITATIVA NOMINAL
- Transmission Overdrive Code : CUALITATIVA NOMINAL
- Transmission Overdrive Desc : CUALITATIVA NOMINAL

Parámetros mecánicos del ensayo

- Equivalent Test Weight (lbs.) : CUANTITATIVA CONTINUA
- Axle Ratio : CUANTITATIVA CONTINUA
- N/V Ratio : CUANTITATIVA CONTINUA
- Shift Indicator Light Use Cd : CUALITATIVA NOMINAL
- Shift Indicator Light Use Desc : CUALITATIVA NOMINAL

Información del ensayo

- Test Number : CUALITATIVA NOMINAL
- Test Originator : CUALITATIVA NOMINAL
- Analytically Derived FE? : CUALITATIVA NOMINAL BINARIA (DICOTÓMICA)
- Test Procedure Cd : CUALITATIVA NOMINAL.
- Test Procedure Description : CUALITATIVA NOMINAL
- Test Fuel Type Cd : CUALITATIVA NOMINAL
- Test Fuel Type Description : CUALITATIVA NOMINAL
- Test Category : CUALITATIVA NOMINAL

Tipo de combustible

- THC (g/mi) : CUANTITATIVA CONTINUA
- CO (g/mi) : CUANTITATIVA CONTINUA
- CO2 (g/mi) :CUANTITATIVA CONTINUA
- NOx (g/mi): CUANTITATIVA CONTINUA
- PM (g/mi) : CUANTITATIVA CONTINUA
- CH4 (g/mi): CUANTITATIVA CONTINUA
- N2O (g/mi) : CUANTITATIVA CONTINUA

Economía de combustible

- RND_ADJ_FE (MPG) : CUANTITATIVA CONTINUA
- FE_UNIT : CUALITATIVA NOMINAL
- FE Bag 1 (MPG) : CUANTITATIVA CONTINUA
- FE Bag 2 (MPG) : CUANTITATIVA CONTINUA
- FE Bag 3 (MPG) : CUANTITATIVA CONTINUA
- FE Bag 4 (MPG) : CUANTITATIVA CONTINUA

Variables ADFE (Analytically Derived FE)

- ADFE Test Number : CUALITATIVA NOMINAL
- ADFE Total Road Load HP : CUANTITATIVA CONTINUA
- ADFE Equiv. Test Weight (lbs.) : CUANTITATIVA CONTINUA
- ADFE N/V Ratio : CUANTITATIVA CONTINUA

Variables de dinamómetro y road load

- DT-Inertia Work Ratio Rating : CUANTITATIVA CONTINUA
- DT-Absolute Speed Change Ratg : CUANTITATIVA CONTINUA
- DT-Energy Economy Rating : CUANTITATIVA CONTINUA
- Target Coef A/B/C : CUANTITATIVA CONTINUA
- Set Coef A/B/C : CUANTITATIVA CONTINUA

*Los coeficientes **A**, **B** y **C** describen la resistencia al avance utilizada en la simulación del vehículo sobre el dinamómetro.*

Postratamiento de emisiones

- Aftertreatment Device Cd : CUALITATIVA NOMINAL
- Aftertreatment Device Desc: CUALITATIVA NOMINAL

Variables de averaging

- Averaging Group ID : CUALITATIVA NOMINAL
- Averaging Weighting Factor : CUANTITATIVA CONTINUA
- Averaging Method Cd : CUALITATIVA NOMINAL
- Averging Method Desc : CUALITATIVA NOMINAL

Variable especial

- Police - Emergency Vehicle? : CUALITATIVA NOMINAL BINARIA (DICOTÓMICA)

2.2 Análisis Univariado:

Analizamos las variables continuas y discretas por separado (“RND_ADJ_FE“, “Axle Ratio“) mediante estadísticas descriptivas (media vs. mediana, asimetría) y diagramas de caja (boxplots). En esta etapa detectamos e investigamos outliers extremos e imposibles de recolección (como el error de tipeo de 10.000 MPG en vehículos a gasolina). Además al conocer el dominio, identificamos una métrica de eficiencia oculta para alguien que no lo conocía. La variable “Axle ratio” podría decirnos mucho y tomamos la decisión de investigarla más en nuestro dataset.

Analizamos el porqué “Axle Ratio” se concentraba en valores bajos, construimos la hipótesis univariada para verificar las tendencias centrales de la flota a combustión evaluando el “Axle Ratio” .

2.3 Análisis Bivariado:

Exploramos la asociación directa entre pares de atributos: evaluamos relaciones continuas (potencia vs. CO2 con correlación de Pearson r = 0.82) y cruzamos variables categóricas con numéricas tracción con RND_ADJ_FE (planteado por la cátedra) y transmisión con CO2. Este último surgió de investigar sobre los contenidos técnicos de ciertas variables en el dataset. Se observó que en ciclos urbanos donde constantemente hay arranques, frenadas, velocidades bajas, ralentí y tráfico, la transmisión cambia de marcha o de relación muchísimas veces. A su vez, es en este mismo contexto que se da la mayor emisión de gases, en especial de CO2, que es el principal gas de efecto invernadero. De esta manera creímos pertinente analizar la relación entre estas dos variables.

2.3 Análisis Multivariado:

Comprendimos que en motores de combustión interna las características técnicas (potencia, cilindrada, cilindros, peso) y las emisiones (CO2, CO,THC, CH4) interactúan en conjunto. Filtramos el universo urbano de combustión y seleccionamos gases relevantes para evitar ruido, y estandarizamos las escalas para evitar variables con un peso alto “falso”. Inicialmente habiamos decidido trabajar sobre “Aftertreatment test” pero al probar la hipotesis no nos parecio que aportara informacion relevante. Tal que asi, formulamos la

hipótesis de que la potencia determina el perfil multidimensional de emisiones de la flota, permitiendo segmentar por su número de cilindros, permitiendonos visualizar como afectaban el incremento de estos en sus emisiones de gases contaminantes..

2.4 Discrepancia en hipotesis urbanas

Al abordar el ciclo urbano en el conjunto de datos de la EPA para las diferentes hipótesis, tuvimos dos criterios distintos que coexisten en un mismo ámbito (con diferentes consideraciones).

Por un lado en las hipótesis 1 (cátedra) sección 3.1 del informe y en la hipótesis 3 (grupo) sección 3.6 del informe, se trabajó bajo un criterio específico de *laboratorio*. Esta consiste en seleccionar los *protocolos federales* donde la EPA mide y certifica formalmente la economía de combustible en frío y calor con canasto evaporativo (Federal fuel 2-day exhaust (w/can load) y Federal fuel 3-day exhaust).

Por otro lado, en el resto de hipótesis se usó un criterio mas *general* de la EPA (empleado en el resto de las hipótesis, en las secciones 3.2, 3.3, 4.1 y 4.2 del informe) basado en filtrar por la categoría general de prueba *Test Category == 'FTP'*.

3. Hipótesis

3.1. Hipótesis 1 propuesta por la cátedra

3.1.1. *"La mayoría de las configuraciones de vehículos a combustión alcanzan al menos 25 MPG de economía de combustible en condiciones de conducción urbana."*

Para agencias regulatorias como la EPA (Agencia de protección ambiental) y el DOT (Departamento de transporte de EE.UU.) , evaluar la eficiencia en ciclo urbano es muy importante. La conducción en ciudad simulada en los tests representa el escenario de mayor exigencia energética al simular una conducción cotidiana con semáforos, frenadas en cada esquina y cambios de marchas constantes. Por lo cual, demostrar si la mayoría de las configuraciones tradicionales superan las 25 millas por galón ayuda a brindar a los reguladores y consumidores una línea base objetiva para regular las flotas de vehículos.

(*Sección 4.1 entrega.ipynb*)

3.1.2. Estrategia de abordaje

Para restringir ciclo urbano y vehículos de combustión se siguió el mismo camino que en la sección 3.3.2.

Al trabajar con los datos pudimos analizar unos valores atípicos extremos en la columna “*RAND_ADJ_FE*” con valor de 10.000 mpg.

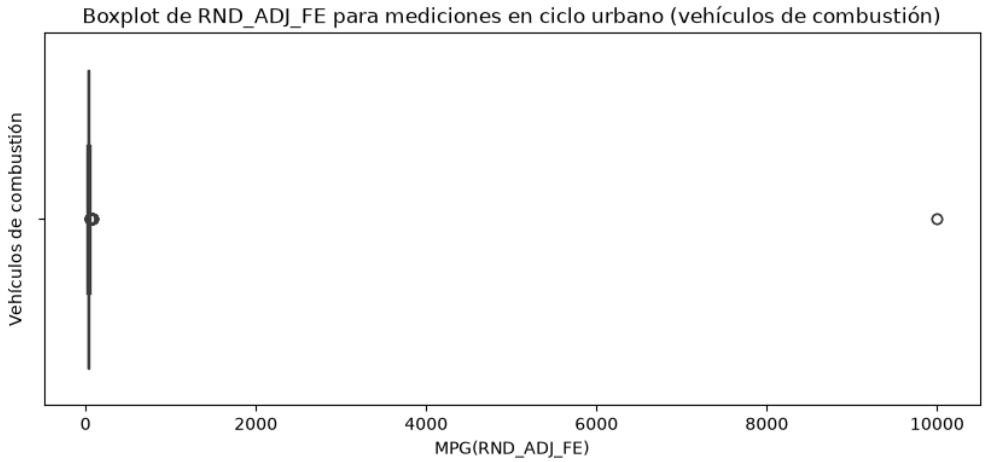


Gráfico 11: Boxplot de MPG (urbano) en vehículos de combustión

La decisión que se tomó fue excluir los dos valores atípicos para el análisis de la hipótesis 1. Estos valores pueden ser un error de carga, en un motor a gasolina que un galón rinde 10.000 millas es físicamente imposible, por lo que se atribuye el valor a un error en la recolección del dato.
Hay que diferenciarlos de los outliers legítimos, observaciones atípicas que pertenecen a la distribución real, como en los casos de los automóviles híbridos que pueden ser ultra eficientes o los eléctricos.

Seguimos trabajando y aplicamos un tratamiento estadístico de outliers con IQR
Sobre los datos físicamente válidos aplicamos la regla del Rango intercuartílico (1.5 * IQR) de John Tukey.

Métrica	**Valor en RND_aDJ_fE**
Media	27.504496 MPG
Mediana	7.419201 MPG
Primer cuartil	26.800000 MPG
tercer cuartil	33.000000 MPG
umbral inferior estadístico	5.24 MPG
umbral superior estadístico	50.74 MPG

Tabla 3 : Información en columna "RND_ADF_FE" usando .describe(), información estadística.

Calculando la distribución de frecuencias de la variable cuantitativa continua "RND_ADJ_FE" se obtuvieron las medidas robustas de centralidad (Mediana), e inspeccionando visualmente la muesca de confianza (notch) mediante un diagrama de caja (boxplot) pudimos observar que los 25 MPG eran superados. Pero debíamos aun probarlo estadísticamente.

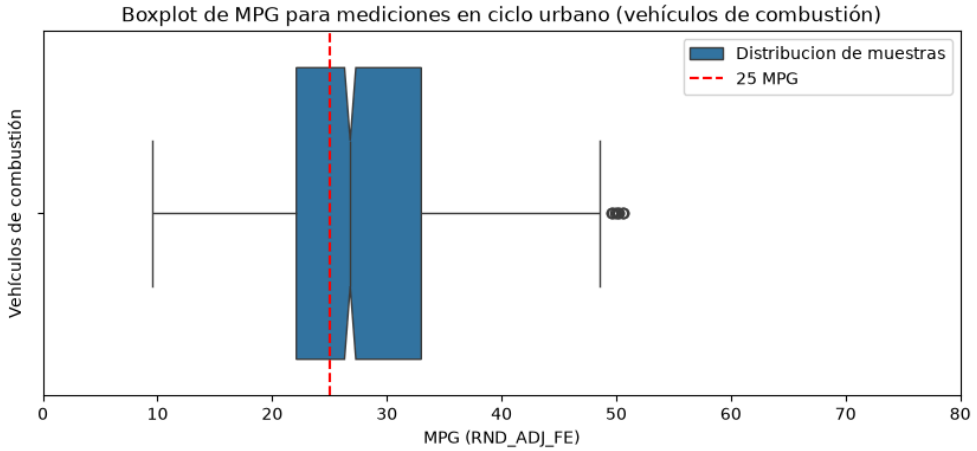


Gráfico 12 : [Diagrama Boxplot en Celda x del Notebook]
Visualización: Muesca (notch) en 26.8 MPG > Umbral de 25 MPG. Límites IQR en 50.8 MPG.

Entendiendo un poco más el dominio

El IQR marca los híbridos como outliers, ya que la mayoría de los automóviles son a combustión tradicional por lo que se fija el límite superior alrededor de 50 MPG.

Los vehículos híbridos convencionales (HEV, como toyota pyrus) no se enchufan a una red eléctrica sino que la obtienen quemando combustible y recuperando energía al frenar.

Se aborda más a profundidad en la sección 3.5.2 del informe.

3.1.3. Resultados obtenidos y discusión

Para probar la veracidad de la hipótesis decidimos trabajar con el test de Wilcoxon para comparar distribuciones o tendencias centrales entre las muestras.

***H0** : La mediana es <= 25 MPG*
***H1** : La mediana es > 25*

Optamos por el test no paramétrico debido a que al realizar un histograma observamos una distribución asimétrica. *(Sección 4.1.2 entrega.ipynb)*
De igual forma lo corroboramos estadísticamente con el test de Shapiro-Wilk

statistic = 0.98	**p value = 9.667e-12**

Siendo el p-valor un número muy chico cercano a cero y claramente menor a 0.05 (lo mínimo requerido para afirmar normalidad) podemos afirmar que la distribución no es Normal, visualizándolo también gracias a un *QQ-PLOT*.

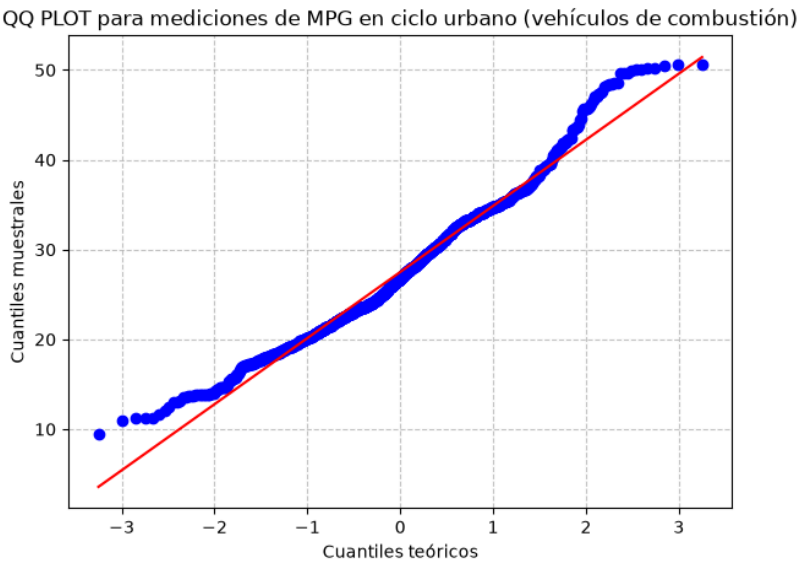


Gráfico 13 : Visualización gráfica con QQ-PLOT sobre distribución.

Las muestras se curvan en los extremos y desvían de la recta ideal, mostrando una asimetría de la variable confirmando que se debe usar un test no paramétrico para analizar estadísticamente la hipótesis.

Estadístico Wilcoxon (w): 476606.5000	**Valor p: 0.0000**

3.1.4. Conclusión Hipótesis 1

El p-valor < 0.05 indica que existe evidencia estadística suficiente para rechazar la hipótesis nula (H0). Esto puede afirmar la hipótesis alternativa(H1), confirmando que la mediana de la eficiencia en la ciudad es superior a 25 MPG. Dado que la mediana marca el punto donde se ubica la mitad de la distribución, se concluye que la mayoría de las configuraciones de vehículos a combustión alcanzan al menos 25 MPG en condiciones de conducción urbana.

3.2. Hipótesis 2 propuesta por la cátedra:

3.2.1. *“En vehículos de combustión, la economía de combustible difiere según el sistema de tracción del auto”.*

¿Por qué sería de utilidad validar esta hipótesis? Para las agencias regulatorias involucradas, la EPA (Agencia de protección ambiental) y el DOT (Departamento de transporte de EE.UU.), poder reconocer diferencias significativas entre la economía de combustible de los distintos tipos de tracción permitiría entender que existe una necesidad de fijar estándares apropiados de medición por categoría para evitar penalizar injustamente

a ciertos tipos de vehículos, los cuales por su tracción inherentemente puedan tener un mayor o menor MPG.

Desde el lado empresarial, permitiría a una organización que precise comprar cientos de vehículos saber que primero debería tomarse el tiempo de saber que tipo de tracción tendrían los autos según necesidad, dado que pesara en la economía de combustible y por lo tanto en los gastos de la empresa.

3.2.2. Estrategia de abordaje

Al igual que ocurrió con la hipótesis bivariada propuesta por nuestro grupo, se empezó analizando y limpiando el DataSet y las variables involucradas en el testeo y análisis de la hipótesis. La idea fue eliminar vehículos eléctricos e híbridos que utilicen Hydrogen 5 (Además aquí se decidió eliminar todos los híbridos, observar más adelante), eliminar valores nulos, 0's y outliers que indiquen potenciales errores de registro o nulos escondidos, y por ultimo, modificación del DataSet para cumplir independencia.

Primero se arrancó analizando y limpiando la variable RND_ADJ_FE (Economía de combustible). Esta presentó resultados muy extraños en su describe. Una media muy por encima de la mediana (asimetría con cola a derecha), un desvío estándar sumamente superior a la media (datos muy heterogéneos), y por sobre todas las cosas un valor máximo de 10.000, el cual junto a otros potenciales outliers, apuntaba a ser el principal responsable de todo lo anterior nombrado. Por lo que habrá que investigar este outlier y la potencial presencia de otros en la variable.

Antes de seguir con lo anterior, se limpiaron sus nulos, un total de 130 filas.
Se investigaron y resultaron todos deberse a una única razón:

Grupo	Combustible	Procedimiento de ensayo	Razón
PHEV en modo Charge Depleting (CD)	Tier 2 Cert Gasoline	Charge Depleting UDDS (65) y Charge Depleting Highway (65)	En modo CD (Charge Depleting) el motor no quema gasolina, por lo que no hay consumo de combustible que reportar. CO2, THC, CO y NOx también están 100 % vacíos.

Ahora si, continuando con los outliers presentes en RND_ADJ_FE, primero se realizó un BoxPlot para poder visualizar de manera general y aproximada, cantidad y distribución.

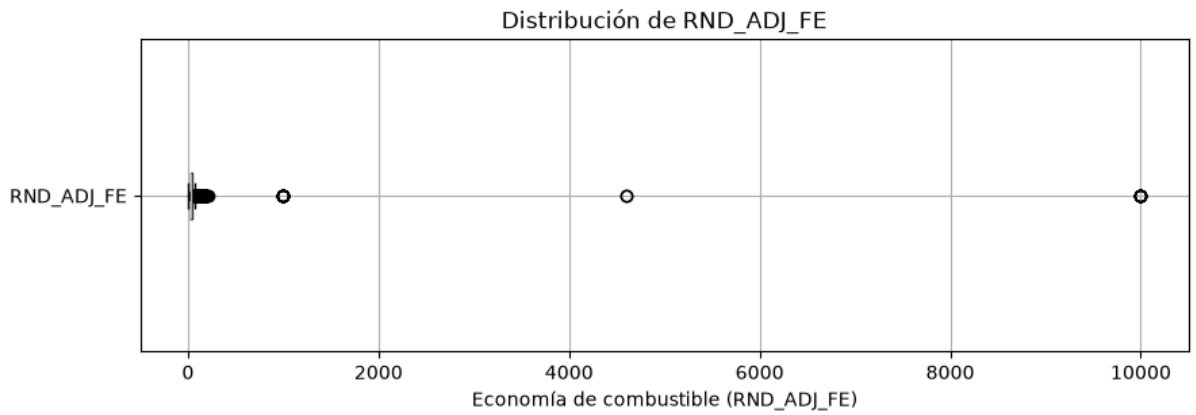


Gráfico 14: Boxplot de MPG sin ajustar

Como se sospechaba, hay un salto abismal entre el último valor creíble (82,8 MPG) y las siguientes 8 filas con un valor de 9999,9999999 (≈ 10.000 en la tabla; claramente un valor no plausible para MPG e implicaría "dato no disponible") y 2 filas con 4595,3 y 4599,1 MPG. Ningún auto rinde así (4.595 MPG equivaldrían a casi 2.000 km por litro), por lo que se trataron como errores de registro y se eliminaron.

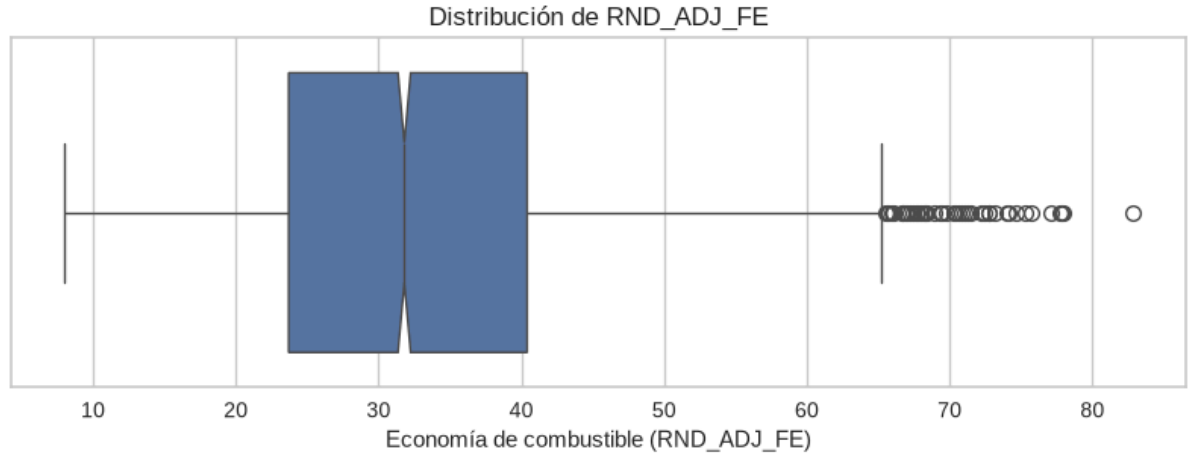


Gráfico 15: Boxplot de MPG ajustado

Tras la limpieza el rango es 8,0 – 82,8 MPG, coherente con autos reales. Aun así, decidimos analizar estos outliers utilizando la regla del rango intercuartílico (1.5* IQR) de Tukey, estableciendo un “techo de confianza”.

Investigando sobre todos aquellos vehículos que superan el límite superior planteado (65.44999999999999 MPG) hallamos dos grupos:

- **Grupo 1 (híbridos):** Toyota Camry HEV AWD LE, Camry HEV FF LE, Corolla Cross Hybrid AWD, Corolla Hybrid, Corolla Hybrid AWD, Prius, Prius AWD, Prius AWD XLE/LTD, Prius Prime, Prius Prime SE y Prius XLE/LTD; Lexus UX 300h; Hyundai Elantra Hybrid, Elantra Hybrid Blue y Sonata Hybrid; Kia Niro Hybrid y Niro PHEV.

- **Grupo 2 (combustión o desconocidos):** Honda Civic 4Dr y Civic 5Dr, que figuran como autos a combustión, y Honda Accord y Accord Sport/Touring, que tienen versiones híbridas en el mercado, pero se desconoce si es el caso porque ni el nombre, ni ningún atributo del DataSet lo aclara.

Se tomó la decisión de eliminar todos aquellos autos en esta lista, menos las correspondientes al Honda Civic 4Dr y Civic 5Dr, los cuales se determinó que no eran híbridos. Todo esto con el objetivo de poder abordar de mejor manera la hipótesis y poder tener resultados más representativos acordes a los autos que son exclusivamente a combustión. Si queremos analizar el MPG de estos, los híbridos distorsionan los resultados porque funcionan de una manera distinta. Rinden bastante más millas por galón gracias al motor eléctrico, por lo que es normal que obtengan un MPG mayor.

Finalmente, se volvió a hacer un resumen de la economía de combustible y las medidas de resumen mejoraron considerablemente. Con una media y mediana más parejas y pegadas, un desvío estándar adecuado al resto de valores, y aunque cuenta aún con los outliers que mantuvimos, es acorde a lo que se quiere testear.

Para terminar con "*RND_ADJ_FE*" se abordó la posible incidencia que podría tener el Test Category realizado en un vehículo sobre su economía de combustible. ¿Por qué? Se investigó que manejar en ciudad obliga al motor a trabajar de forma poco eficiente. En un ciclo urbano hay muchas frenadas, arranques y paradas, y cada vez que el auto tiene que volver a acelerar desde cero, el motor gasta mucho combustible para vencer la inercia. Además, en los semáforos o en el tráfico el motor sigue encendido en ralentí, consumiendo nafta sin avanzar ni un metro.

Lo mismo ocurriría con los ciclos de SCO3 (de este no quedan en el DataSet limpio) o US06, este último por sobre todo, dado que presenta un tipo de test de conducción agresiva y a alta velocidad. Tiene aceleraciones fuertes y velocidades que llegan a unas 80 mph (cerca de 130 km/h). Como el motor trabaja con más carga, el MPG suele ser menor que en el ciclo de autopista normal

En cambio, en un ciclo de autopista el auto va a velocidad más o menos constante. El motor trabaja en un régimen estable y eficiente, sin tener que acelerar y frenar todo el tiempo, y por eso recorre más millas por galón. Para abordar esto, se decidió testear la hipótesis de economía de combustible según tracción por cada tipo de Test Category, para evitar que cualquier potencial resultado se vea sesgado por la presencia de una mayor cantidad de observaciones de un Test Category en una tracción en específico.

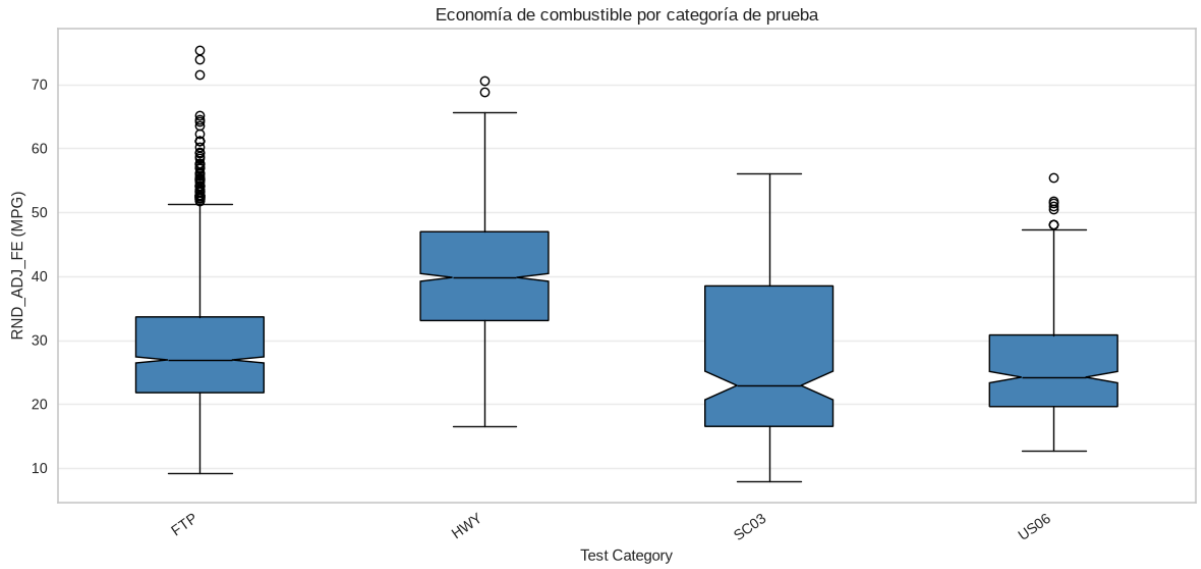


Gráfico 16: FE por ciclo realizado.

Como se adelantó, HWY cuenta con los valores más altos, con una mediana cercana a 40, porque a velocidad constante el motor trabaja de forma más eficiente. Las otras tres pruebas (urbano, aire acondicionado y conducción agresiva) tienen medianas parecidas y más bajas, entre 23 y 27, porque en todas el motor se exige más ya sea por las frenadas y arranques, por el aire acondicionado, o por las aceleraciones fuertes.

Para garantizar independencia entre las observaciones se decidió agrupar por Veh Mfr Code, Test Vehicle ID y Test Veh Configuration, colapsando los valores de economía de combustible, en caso de haber varios, a un único por vehículo utilizando la mediana. En este caso se hizo por cada uno de los subgrupos creados.

Por último, detallar que “Drive System Description” o lo que sería tracción, no cuenta con valores NaN que precisen tratamiento.

Antes de pasar a realizar los tests sobre los supuestos, se realizó un resumen de frecuencia sobre cada tipo de tracción para cada categoría de test. De manera general para todas las categorías de tests, se halló que Part-Time 4-Wheel Drive contaba con un N muy chiquitito, poco representativo y poco confiable, por lo que se decidió excluirlo del test de hipótesis.

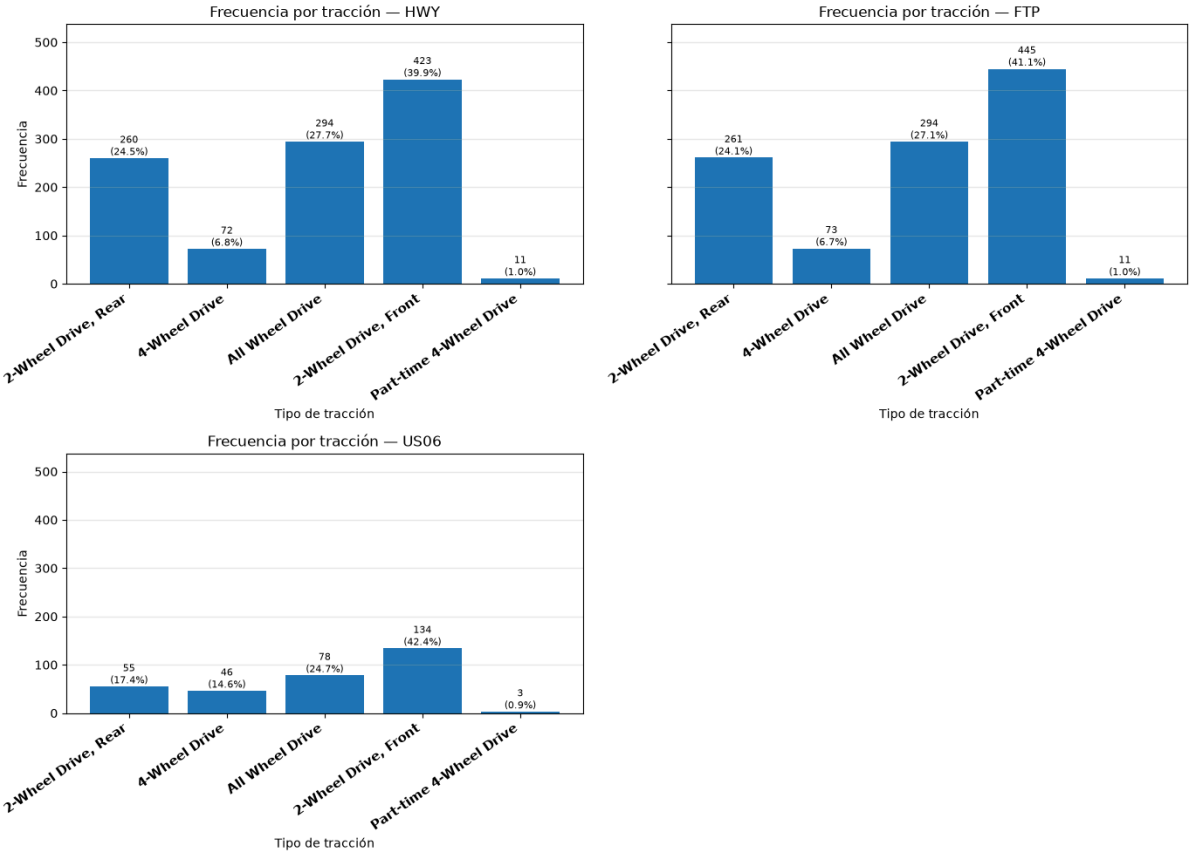


Gráfico 17: Frecuencias por tipos de tracción en los ciclos realizados.

Por último se realizaron de la misma manera, gráficos de boxplots con muescas para observar las distribuciones por tipo de tracción de la economía de combustible en cada tipo de test.

Los boxplots en este caso nos muestran que “2-Wheel Drive, Front”(tracción delantera) es la que tiene la mejor eficiencia de combustible en las tres pruebas, con una mediana muy por encima del resto de tipos de tracción. Su mediana ronda los 47 en autopista (HWY), 34 en ciudad (FTP) y 33 en conducción agresiva (US06). Las demás, “2-Wheel Drive, Rear” (tracción trasera), “4-Wheel Drive” (tracción 4x4) y “All Wheel Drive” (tracción integral) quedan bastante parecidas entre sí: unos 32 a 36 en autopista, 21 a 24 en ciudad y 19 a 22 en conducción agresiva, con All Wheel Drive (tracción integral) apenas por encima de “2-Wheel Drive, Rear” y “4-Wheel Drive”. Las muecas en general no aparentan coincidir, salvo casos como por ejemplo entre “All Wheel Drive” y “2-Wheel Drive, Front” en US06, pero en general hay diferencias entre la gran mayoría.

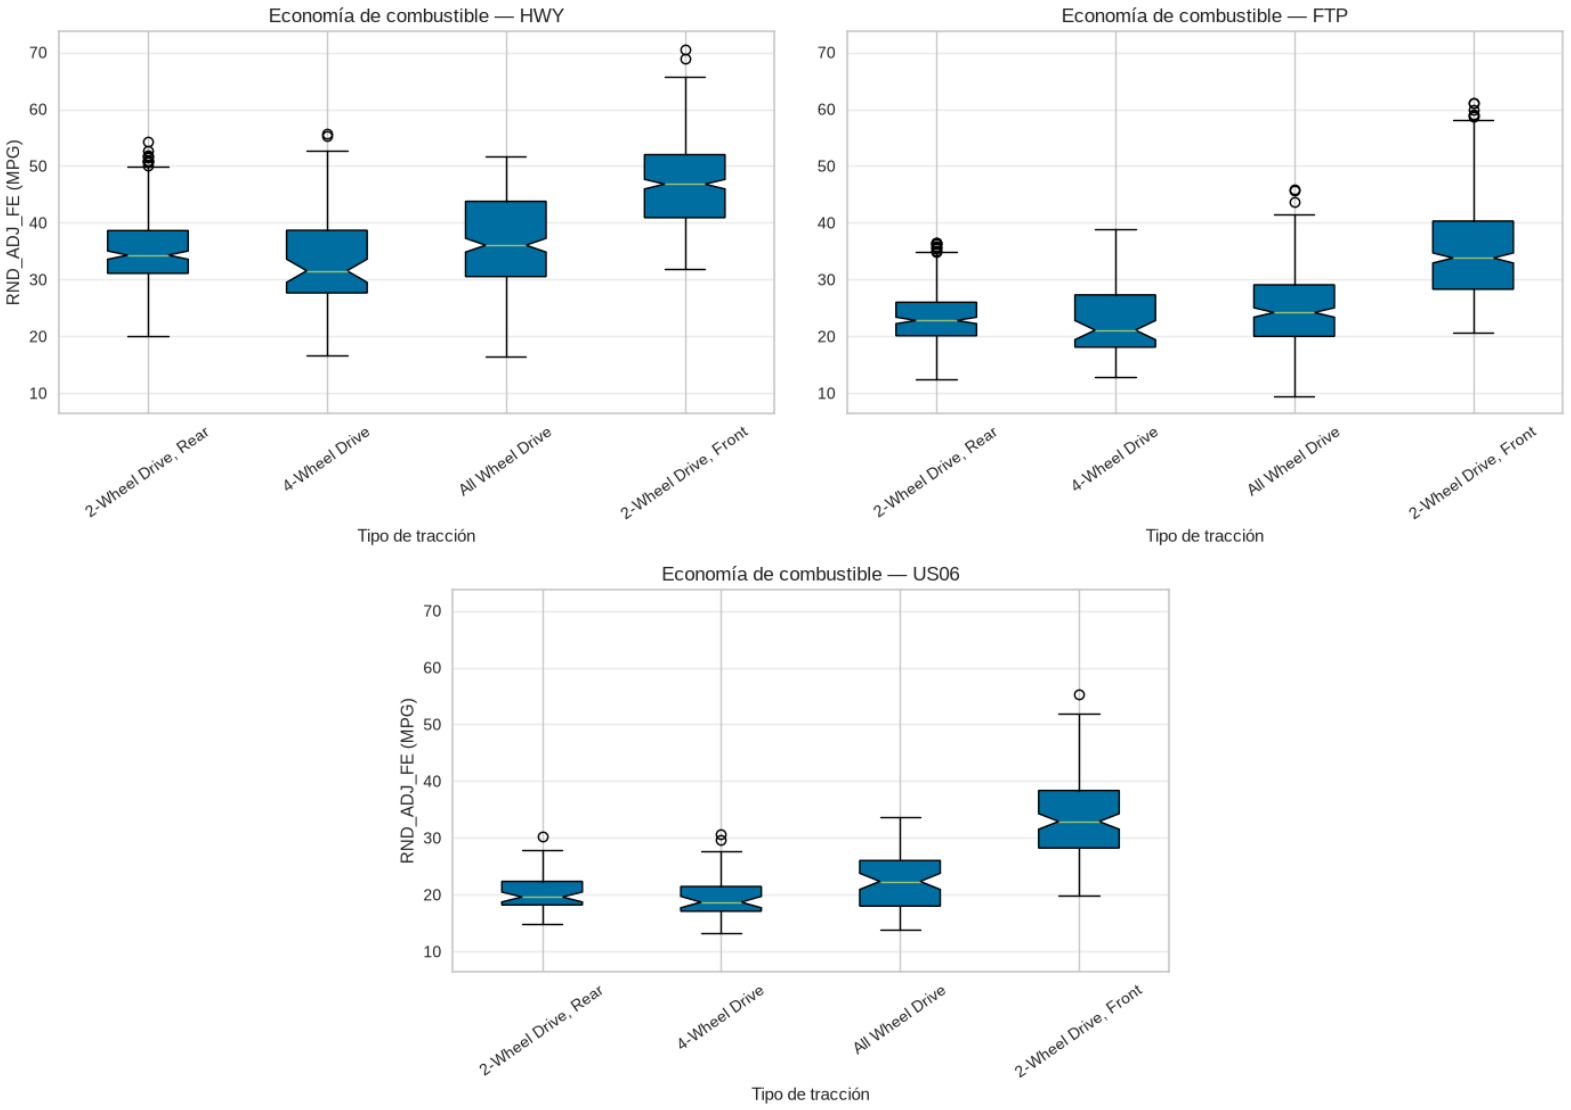


Gráfico 18: Notched BoxPlots de FE por tracción en los ciclos realizados

Todo parece indicar que hay diferencias significativas en la economía de combustible entre los distintos tipos de tracciones en cada categoría de test. Pero hay que probarlo.

Nuevamente, dado que nos aseguramos independencia entre las variables, con más de dos grupos nuestras opciones para llevar a cabo el test de hipotesis con Anova o Kruskall-Wallis. Para el primero será necesario cumplir sus supuestos por lo que procederemos a comprobarlos

- ➢ *Normalidad* (Shapiro-Wilks/QQ-plot) Si no se cumple se pasará directamente a Kruskal-Wallis
- ➢ *Homocedasticidad* (Levene)

3.2.3. Resultados obtenidos y discusión

Observemos los resultados de Shapiro-Wilks para cada tipo de tracción según su economía de combustible, en cada test category:

TEST DE SHAPIRO PARA TEST CATEGORY: HWY

2-Wheel Drive, Front n = 423 Estadístico = 0.9860, p-valor = 0.0004282
2-Wheel Drive, Rear n = 260 Estadístico = 0.9603, p-valor = 1.426e-06
4-Wheel Drive n = 72 Estadístico = 0.9519, p-valor = 0.007899
All Wheel Drive n = 294 Estadístico = 0.9692, p-valor = 6.139e-06

TEST DE SHAPIRO PARA TEST CATEGORY: FTP

2-Wheel Drive, Front n = 445 Estadístico = 0.9483, p-valor = 2.407e-11
2-Wheel Drive, Rear n = 261 Estadístico = 0.9647, p-valor = 5.072e-06
4-Wheel Drive n = 73 Estadístico = 0.9403, p-valor = 0.001806
All Wheel Drive n = 294 Estadístico = 0.9876, p-valor = 0.0126

TEST DE SHAPIRO PARA TEST CATEGORY: US06

2-Wheel Drive, Front n = 134 Estadístico = 0.9591, p-valor = 0.0004885
2-Wheel Drive, Rear n = 55 Estadístico = 0.9319, p-valor = 0.00393
4-Wheel Drive n = 46 Estadístico = 0.9189, p-valor = 0.003453
All Wheel Drive n = 78 Estadístico = 0.9741, p-valor = 0.113

Como se puede observar por los p-valores la gran mayoría no se distribuye normalmente, por lo que no se puede proceder a realizar un test de ANOVA sobre los datos y se tendrá que recurrir a realizar un test de Kruskal-wallis. Remarcar aún así que los tipos de All Wheel Drive bajo ciclo US06 si se distribuyen normalmente respecto a economía de combustible.

Finalmente, como no se cumplieron los supuestos necesarios para realizar ANOVA, procederemos a llevar a cabo Kruskal-Wallis.

Test Category	Statistic	P-value
HWY	**385.577**	**0.000**
FTP	**427.180**	**0.000**
US06	**188.172**	**0.000**

Resultados de test de hipotesis mediante Kruskal-Wallis.

El p-valor < 0.05 como resultado en cada uno de los tests llevados a cabo indica que existe evidencia estadística suficiente para rechazar la hipótesis nula (H0). Esto puede afirmar la hipótesis alternativa (H1). De esta manera se puede afirmar que efectivamente existen diferencias significativas en la economía de combustible entre los vehículos a combustión según su tipo de tracción. Estos resultados invitan a investigar cual es la relación exacta entre la tracción con la que cuenta un vehículo y su eficiencia de combustible, lo que se indaga en profundidad en la próxima hipótesis.

3.3. Hipótesis 3 propuesta por la cátedra:

3.3.1 *“Entre vehículos a combustión, las características técnicas del vehículo (peso, potencia, cilindrada, número de cilindros, transmisión y sistema de tracción) se encuentran asociadas conjuntamente con su eficiencia de combustible urbana.”*

3.3.2 Definición de la hipótesis

En la hipótesis multivariada dada por la cátedra se investiga y analiza cómo los componentes y características inherentes a los vehículos afectan en la economía de los mismos, esto puede llegar a ser de interés a la hora de decidir que auto comprar o fabricar según los estándares de consumo se quieran obtener. Permitiría entender de mejor manera los trade-offs, como se puede llegar a ganar potencia, comodidad o velocidad pero se puede perder eficiencia en el combustible en el uso urbano de vehículos a combustión.

3.3.3. Estrategia de abordaje

Se trabajó sobre el dataset filtrado según la configuración de las muestras (igual valor en **"Veh Mfr Code", "Test Vehicle ID", "Test Veh Configuration #"**) y nuevamente dejando solo los autos a combustión como ya se explicó anteriormente.

Para empezar la investigación primero se analizó cada variable involucrada por separado. El “ *RND_AJD_FE*” se limpio de la misma manera que en el resto de hipótesis.

Exploración de las variables sobre las características técnicas del vehículo:

- Peso ("Equivalent Test Weight (lbs.)): Al analizar la variable descubrimos que no hay nulos, al hacer un describe (count:1087.0, mean:4557.152714 , std:853.084541, min:2750.0, 25%:3875.0, 50%: 4500.00, 75%:5000.0, max:7000.0) observamos los valores únicos que puede llegar a tomar y las veces que se toman y no se observó la existencia de valores irreales que se puedan haber usado para marcar nulos no explícitos, por lo que no se realizó ninguna transformación adicional.

- Potencia (Rated Horsepower): Cero valores nulos, describe (count: 1087.000000, mean:312.644894, std:144.726779, min:1.0, 25%:192.0, 50%:281.0, 75%:382.0, max:1500.0) analizamos más el mínimo y el máximo. El mínimo de 1.0 es un valor imposible para los 2 vehículos que los presentaron, se tomó como un error y se eliminaron esas filas (ya que eran solo 2 filas). Con el máximo de 1500 caballos de fuerza, para poder determinar si era un error o una entrada válida, se investigó y se descubrió que se trataba de un Bugatti Chiron con esas características, por lo cual se dejó esa muestra.

- Cilindrada (Test Veh Displacement (L)) : cero valores nulos, metricas de distribucion (count:1085.0, mean:2.814801, std:1.069135, min:1.20 , 25%:2.0, 50%:2.50, 75%:3.4450, max:7.9930) no dan indicios de anormalidades, tampoco se notaron al hacer un value count y ver los valores que toma la variable.

- Número de cilindros (# of Cylinders and Rotors) : Hay tres nulos, al investigarlos un poco más son simplemente valores faltantes, por lo que se decidió seguir el análisis sin esas muestras. El describe dio los siguientes resultados (count: 1082.0, mean:5.146950, std:1.602968, min:3.0, 25%:4.0, 50%:4.0, 75%:6.0, max:16.0). Se analizó el vehículo con los 16 cilindros y se descubrió que se trataba del mismo Bugatti con el número alto de caballos de fuerza.

- Transmisión (Tested Transmission Type) : no se encontraron nulos y al hacer el describe estos fueron los resultados,count:1082, unique:7, top: Semi-Automatic, freq:402 , estas son las categorías que puede tomar la variable (Semi-Automatic: 402, Automatic: 288, Automated Manual- Selectable (e.g. Automated Manual with paddles):141, Continuously Variable: 127, Selectable Continuously Variable (e.g. CVT with paddles): 66, Manual: 42, Automated Manual: 16) para el mejor manejo y estudio se decidió resumir en solo 5 grupos: CVT (Continuously Variable y Selectable Continuously Variable (e.g. CVT with paddles)), Automatizada (Automated Manual, Automated Manual- Selectable (e.g. Automated Manual with paddles)), Automática (Automatic), Manual (Manual) y Semi-automatica (Semi-automatic), quedando así los grupos (Semi-automatica: 402, Automatica: 288, CVT: 193, Automatizada:157, Manual:42). Para el análisis posterior se decidió que la mejor manera de trabajar con las variables categóricas era con su transformación a dummies, por lo que se agregan al dataset las siguientes columnas: transmision_Automatica, transmision_Automatizada, transmision_Manual, transmision_CVT y transmision_Semi-automatica.

- Tracción: No hay nulos. Al ver las categorías que podía tomar las variables se decidió por agrupar en 3 grupos: Delantera ("2-Wheel Drive, Front"), Trasera (2-Wheel Drive, Rear) e Integral (All Wheel Drive, 4-Wheel Drive y Part-time 4-Wheel Drive). Así quedarían las nueva clasificación: Delantera: 442, Integral:377, Trasera:263 y un describe con los siguientes valores : count: 1082, unique:3, top:Delantera, freq:442 . También se decidió convertirlas en columnas dummies: traccion_Delantera, traccion_Trasera y traccion_Integral.

Al analizar todas las variables por separado pudimos notar que viven en rangos y dominios distintos, por lo cual estandarizamos las variables para poder hacer un buen análisis.

3.3.4. Resultados obtenidos y discusión

Como primer “estudio” de la relación entre las características del vehículo y su economía de combustible se decidió hacer un PCA , para eso solo se tuvo en cuenta las variables numéricas (potencia, peso, cilindrada y número de cilindros)

```
Varianza explicada: [0.769 0.152]
Acumulada: 0.922
                              PC1   PC2
Equivalent Test Weight (lbs.)  0.40  0.92
Rated Horsepower               0.51 -0.26
```

```
Test Veh Displacement (L)       0.53 -0.20
# of Cylinders and Rotors       0.55 -0.24
```

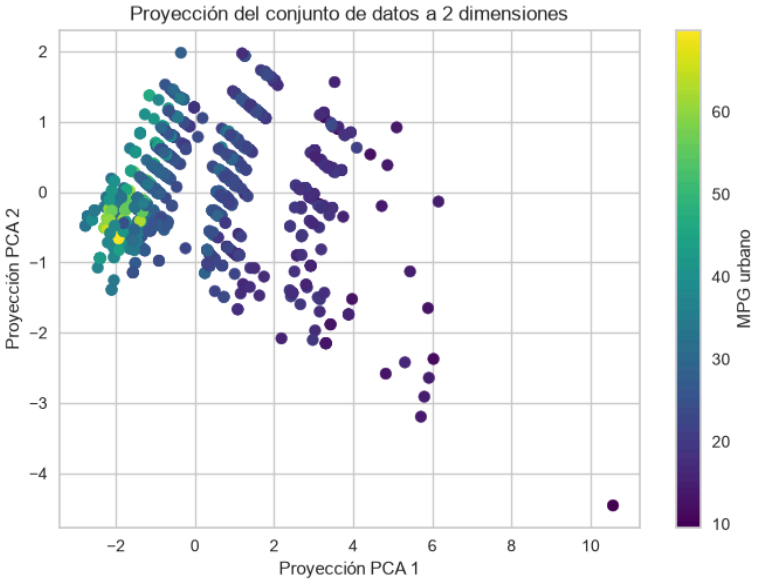


Gráfico 19 : Biplot de PCA con MPG urbano

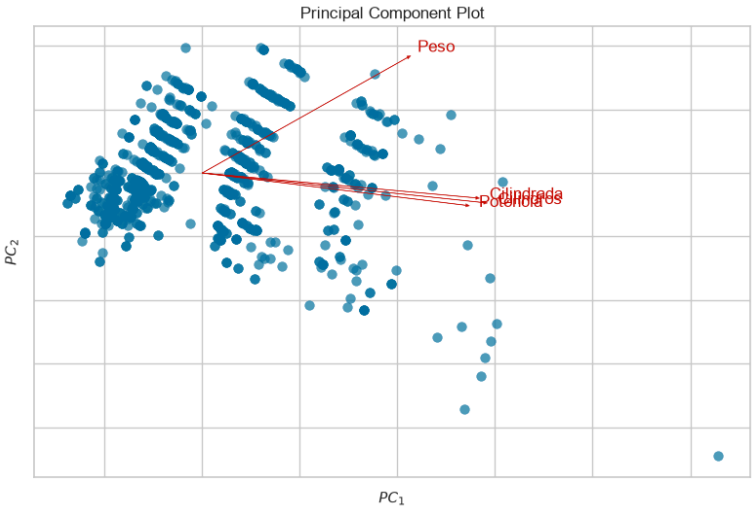


Gráfico 20 : Biplot de PCA con vectores de las variables

PC1 (76,9%) es un índice de “tamaño del motor”. Las cuatro variables pesan con el mismo signo: cilindros (0,55), cilindrada (0,53), potencia (0,51) y peso (0.40, algo menos). Un valor alto de PC1 indica un auto con motor grande y potente, y uno bajo, un auto chico.

PC2 (15,2%) separa el peso del motor. Casi todo el peso de PC2 viene del peso del vehículo (0,92), con signo contrario al de potencia, cilindrada y cilindros (entre −0,20 y −0,26). Un valor alto de PC2 es un auto pesado para el tamaño de su motor (por ejemplo, un SUV con motor chico), y un valor bajo, un auto liviano con motor grande (típico de un deportivo).

El biplot (gráfico 20) muestra que potencia, cilindrada y número de cilindros apuntan en una dirección prácticamente idéntica, lo que indica una correlación muy alta entre ellas y confirma que miden en gran medida el mismo atributo (el tamaño del motor). El peso forma un ángulo mayor con ese grupo, por lo que aporta información en parte independiente, que se refleja en el segundo componente.

El MPG baja de forma clara de izquierda a derecha. Los puntos amarillos y verdes (MPG de 50 a 80) están en la zona de PC1 bajo (motores chicos), y los violetas (MPG de 10 a 20) en PC1 alto. Es la evidencia visual más fuerte a favor de la hipótesis: el tamaño del motor, resumido en un solo eje, se asocia con el consumo.

El punto que se ve separado del resto en el extremo izquierdo inferior es justamente el Bugatti de 16 cilindros y 1500 caballos de fuerza.

Nota: al ver la gran similitud y superposición de las variables cilindrada y número de cilindros se decidió explorar un PCA solo con cilindrada, pero notamos que no cambiaba en gran dimensión la conclusiones, es más bajaba el porcentaje de varianza explicada.

Para un análisis más extensivo de la dimensionalidad y las relaciones no lineales que presenta el dominio se hizo un **t**-SNE (*t-Distributed Stochastic Neighbor Embedding*), una técnica no supervisada de reducción no lineal de la dimensionalidad, estos fueron los resultados:

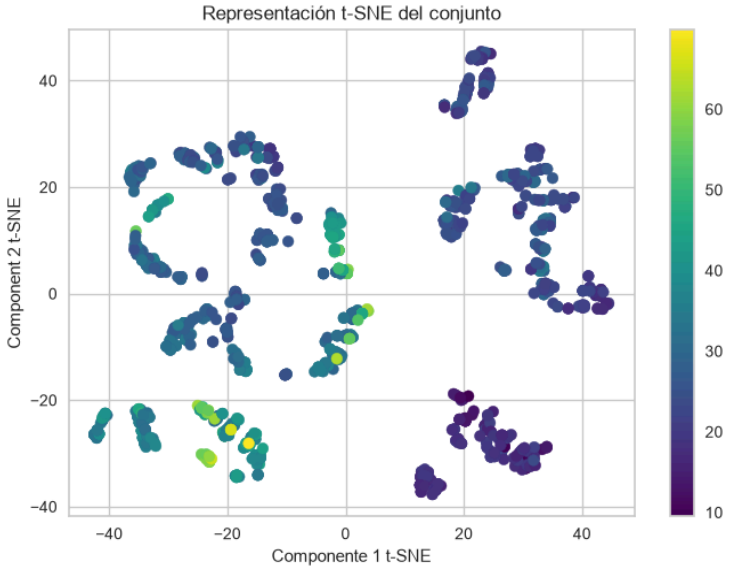


Gráfico 21 : Biplot de T-sne con MPG

Se pueden notar tres grupos, el de la mitad izquierda, que tiene la mayor varianza respecto al índice de MPG que toman y que concentra las muestras con máximo valor de esta. Luego el de la izquierda superior que toma valores de economía del combustible de entre aproximadamente 20-40 y por último el claro grupo de la mitad derecha inferior que concentra los mayores valores de MPG.

Para integrar las variables categóricas se decidió colorear el gráficos de t-sne según el valor que tomaban todas las muestras:

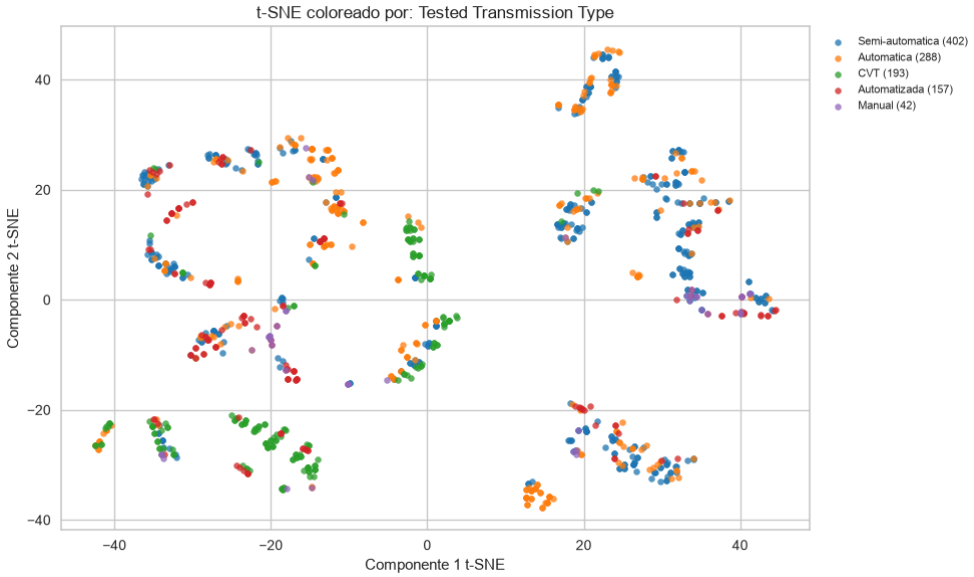


Gráfico 22: gráfico de t-sne con clasificación según la transmisión.

En cuanto a la transmisión el “patrón” más claro que se puede notar es el de CVT, que pareciera que se identifican en las mismas muestras que presentaban mayor eficiencia del combustible.

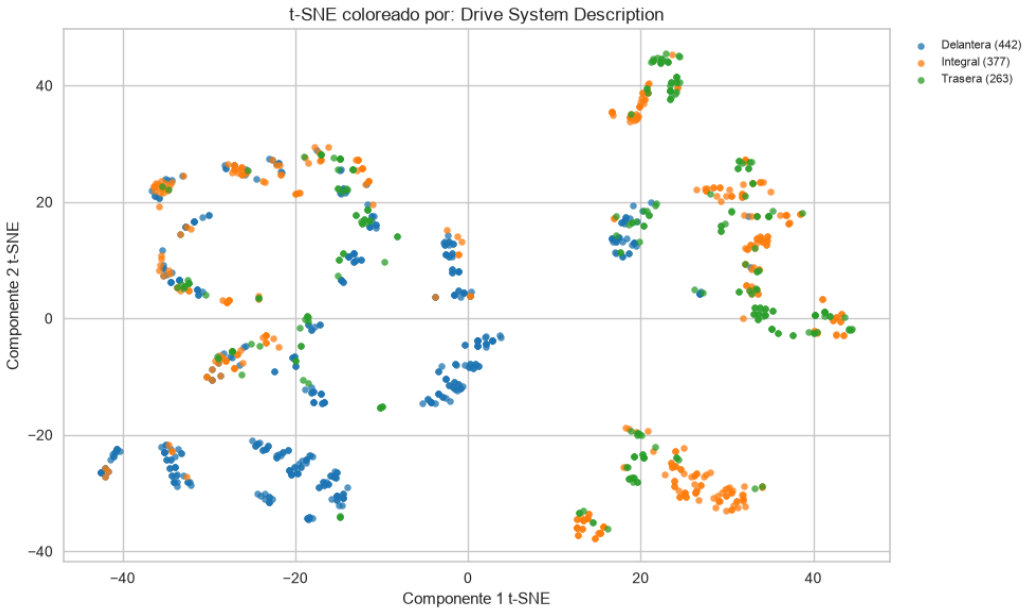


Gráfico 23: gráfico de t-sne con clasificación según la tracción.

Con respecto a las tracciones se ve como las de tracción delantera se concentran el la mitad izquierda del gráfico, donde estaban los casos de los mayores valores de MPG, mientras que los de tracción trasera e integral se identifican en las muestras que menos eficiencia presentaban.

Para poder seguir estudiando estos grupos se hizo un clustering con K Means con k igual a 3, decidido por los gráficos de codo y silueta (en el del codo del gráfico 24, este desacelera en k=3 y es uno de los mayores valores de silueta que se puede tomar)

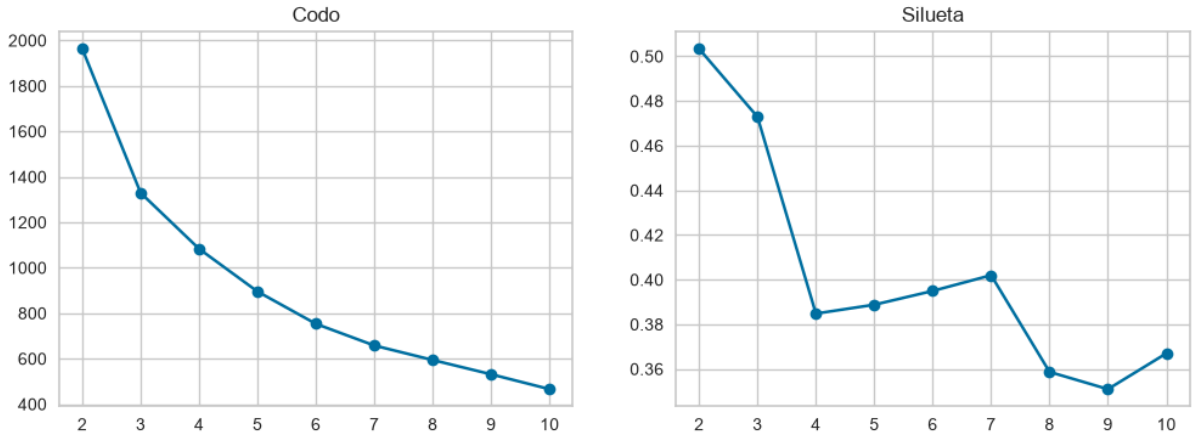


Gráfico 24 : Gráficos de codo y silueta para clustering

Al hacer el proceso de clustering en 3 grupos se llegó a la siguiente agrupación:

cluster	
0	589
1	346
2	147

Con las siguientes variaciones en las características utilizadas para agruparlos y los valores promedios de economía del combustible que toman:

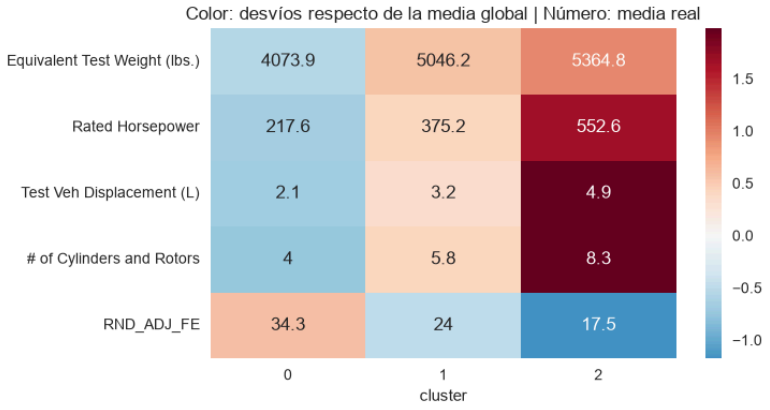


Tabla : comparación del promedio de las variables en cada cluster.

Al identificarlos sobre el gráfico del T-sne previamente dicho quedó el siguiente gráfico:

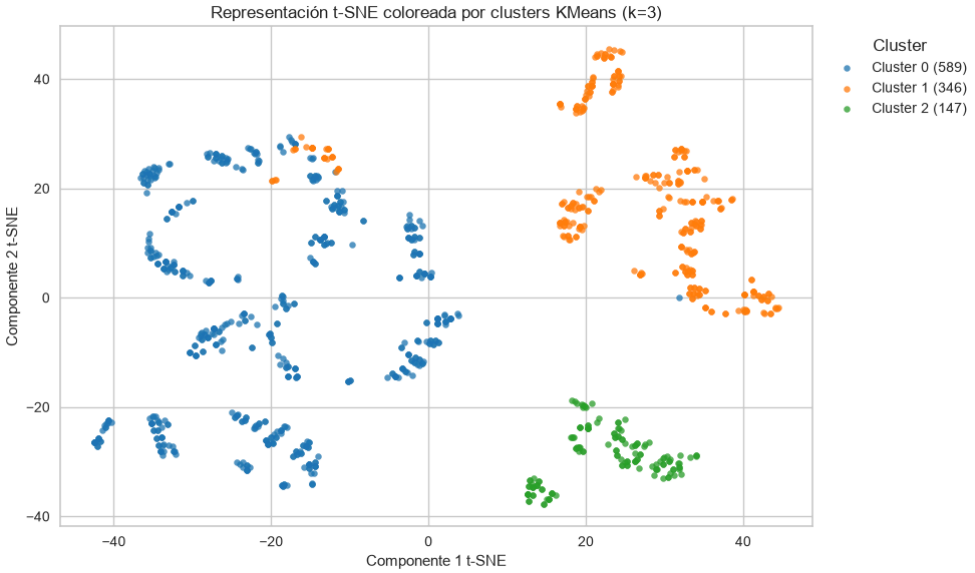


Gráfico 25: Gráfico de t-sne marcando las muestras según los clusters.

Se puede entonces notar más claramente la división de las muestras en tres grupos que se podrían clasificar como:

- Cluster 0: vehículos pequeños, tienen las tendencias más bajas respecto a peso, potencia, cilindrada y número de cilindros, es el grupo mayoritario y tienen el mejor

rendimiento de combustible (MPG más alto).Por lo visto antes, es donde predomina la tracción delantera y donde están las CVT.

- Cluster 1: vehículos medianos, promedio de potencia de 375.2, de peso 5046.2, de cilindrada 3.2 y de número de cilindros 5.8. Tienen en promedio una eficiencia media de 24 (MPG). La mayoría tiene tracción trasera o integral y predominan las transmisiones semi-automáticas y automáticas.
- Cluster 2: vehículos grandes, de alto rendimiento o alto porte, tienen la peor eficiencia de combustible, son de tracción trasera o integral y en su mayoría de transmisión automática o semi-automática. Son el grupo más pequeño y corresponden a los autos deportivos o superdeportivos nombrados anteriormente.

Los vehículos del dataset se organizan en tres perfiles: *livianos y eficientes; intermedios; pesados y potentes;* ordenados por un gradiente de tamaño y potencia que determina el consumo. La separación aparece tanto en el espacio original (K Means) como en la proyección no lineal (t-SNE), lo que le da robustez al resultado.

Para mejor análisis de cómo afectan cada una de las variables de características de los autos a la economía del combustible se decidió hacer también una regresión lineal.

Este fue el resultado:

```
==============================================================================
=
Dep. Variable:              RND_ADJ_FE   R-squared:
0.698
Model:                             OLS   Adj. R-squared:
0.695
Method:                  Least Squares   F-statistic:
128.5
Date:                 Sun, 08 Nov 2026   Prob (F-statistic):
5.64e-153
Time:                         20:02:02   Log-Likelihood:
-3319.3
No. Observations:                1078   AIC:
6661.
Df Residuals:                    1067   BIC:
6715.
Df Model:                          10
Covariance Type:               cluster
==============================================================================
                                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
const                         27.6494      0.348     79.538      0.000      26.968      28.331
Equivalent Test Weight (lbs.) -0.9916      0.231     -4.284      0.000      -1.445      -0.538
Rated Horsepower              -4.5082      0.455     -9.910      0.000      -5.400      -3.617
Test Veh Displacement (L)     -3.0397      0.501     -6.070      0.000      -4.021      -2.058
# of Cylinders and Rotors      2.6053      0.658      3.958      0.000       1.315       3.895
transmision_Automatica        -0.3698      0.341     -1.084      0.278      -1.038       0.299
transmision_Automatizada       2.0751      0.597      3.474      0.001       0.905       3.246
transmision_CVT                8.9828      0.908      9.892      0.000       7.203      10.763
transmision_Manual            -2.8668      0.558     -5.137      0.000      -3.961      -1.773
traccion_Integral             -0.8901      0.556     -1.601      0.109      -1.980       0.200
```

```
traccion_Trasera                -1.1022      0.517     -2.134      0.033      -2.115      -0.090
...
================================================================================
=
```

Interpretación:

- El R^2 indica que el modelo explica aproximadamente el 69,8 % de la variabilidad observada en la eficiencia urbana.
- El R^2 ajustado es 69,5 %, muy cercano al R^2. Esto indica que el poder explicativo se mantiene al considerar la cantidad de variables incluidas.
- El p-valor de la prueba global es extremadamente pequeño (menor a 0,05). Por lo tanto, rechazamos la hipótesis nula de que todos los coeficientes explicativos sean simultáneamente iguales a cero. Esto proporciona evidencia estadística a favor de la hipótesis.

Los resultados muestran que el peso, la potencia y la cilindrada presentan asociaciones negativas y estadísticamente significativas con la eficiencia urbana: un aumento de una desviación estándar en estas variables se asocia con una disminución de 0,9916, 4,5082 y 3,0397 unidades de MPG, respectivamente. Por el contrario, el número de cilindros presenta una asociación positiva y significativa, con un incremento de 2,6053 unidades de MPG por cada desviación estándar adicional. En cuanto a la transmisión, tomando como referencia la semiautomática, la transmisión automatizada se asocia con un aumento de 2,0751 unidades de MPG y la CVT con un aumento de 8,9828, mientras que la manual se relaciona con una disminución de 2,8668 unidades; todas estas diferencias son estadísticamente significativas. La transmisión automática, en cambio, no presenta una diferencia estadísticamente significativa respecto de la categoría de referencia (p = 0,278). Respecto al sistema de tracción, tomando como referencia la delantera, la tracción trasera presenta una asociación negativa y significativa de 1,1022 unidades de MPG, mientras que la integral no muestra una diferencia estadísticamente significativa (p = 0,109).

Al chequear los supuestos de los residuos llegamos a estas métricas y gráficos:

```
Omnibus: 262.51699850921494
Prob(Omnibus): 9.889129653148805e-58
Durbin-Watson: 0.9308147708794507
Jarque-Bera: 754.456736973925
Prob(JB): 1.4852554297976706e-164
Skew: 1.2233859734862949
Kurtosis: 6.287874314837854
Condition Number: 10.423555546057326
```

Por los resultados obtenidos en Prob(ómnibus) y Prob(JB), ambos menores a 0.05, no se cumple el supuesto de normalidad. El valor del estadístico Durbin-Watson es de 0.930, lo cual sugiere autocorrelación positiva lo cual va en contra del supuesto de independencia. Viendo el gráfico de residuos vs valores ajustados vemos que las muestras

no se distribuyen de manera uniforme alrededor del 0, lo cual va en contra del supuesto de homocedasticidad.

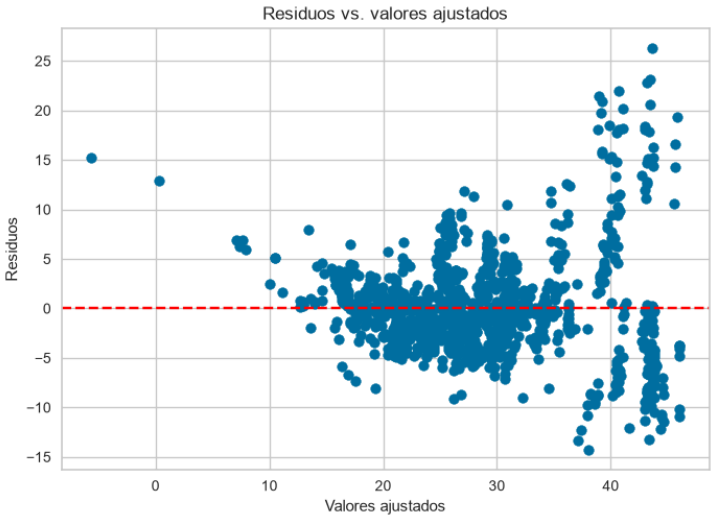


Grafico 26: Residuos vs valores ajustados

Como no se cumplen los supuestos no se puede usar la regresión lineal para refutar o aceptar la hipótesis, pero viendo el análisis del PCA, T-sne y cluster se considera que hay suficiente evidencia estadística para constatar que entre vehículos a combustión, las características técnicas del vehículo (peso, potencia, cilindrada, número de cilindros, transmisión y sistema de tracción) se encuentran asociadas conjuntamente con su eficiencia de combustible urbana.

Hipótesis propias:

3.4 Hipótesis univariada propia:

3.4.1. “En los autos de combustión testeados por EPA en 2025, presentan una mediana de Axle ratio menor a 3.73”

En la hipótesis univariada que formulamos decidimos estudiar la variable Axle Ratio, Al empezar la investigación adicional para conocer el dominio nos pareció un concepto interesante para poder entender cómo las características del auto acotan su rendimiento, y como las tendencias de los autos analizados en el estudio pueden llegar a condicionar los resultados de los siguientes análisis del informe.

El axle ratio (conocido en español como relación de eje o relación del diferencial) es el número de vueltas que debe dar el eje de transmisión (o el piñón) por cada vuelta completa de las ruedas motrices. Al investigar llegamos a la información de que una relación numérica baja (Ej: 2.73, 3.08, 3.21) gira el motor a menos revoluciones por minutos a altas velocidades, tiene menor fuerza de arranque y menos capacidad para remolcar o subir pendientes pronunciadas. Mientras que una relación numérica alta (3.73, 4.10, 4.56 o superior) implica mayor fuerza y mayor aceleración desde 0, pero el motor va más

revolucionado a la misma velocidad, elevando el consumo de combustible y reduciendo la velocidad máxima.

***H0**: mediana(Axle ratio) <= 3.73*
***H1**: mediana(Axle Ratio) > 3.73*

Se decidió ir con un análisis de la mediana y no de la media, ya que esta es menos sensible a outliers, y esta distribución tiene una elevada cantidad (como se puede ver en el gráfico 1)

3.4.2. Estrategia de abordaje

Primero empezamos filtrando el dataset para quedarnos solo con una fila por auto, usando como elemento de filtrado la variable “Test Vehicle ID” (valor único por auto testeado). Luego filtramos para dejar los ensayos de los autos a combustión, para eso filtramos la columna “Test Fuel Type Description” y sacamos aquellos que en la descripción incluyen “Electricity” o “Hidrogen”, para este análisis de hipótesis consideramos prudente dejar los autos híbridos (vehículos que combinan un motor de combustión interna con uno o más motores eléctricos) ya que consideramos que igual cuentan como autos a combustión y sacarlos sería un error para el análisis integral de estos.

Esta serie de filtraciones nos deja con 740 muestras, de las cuales ninguna era nula (Nan). Al hacer un describe y un value count de la variable Axle Radio no pudimos distinguir si hay nulos no explícitos, es decir, resultados erróneos o inverosímiles que se ponen como relleno al no tener respuesta.

Se hicieron los siguientes gráficos para empezar a entender un poco la distribución y el comportamiento de la variable.

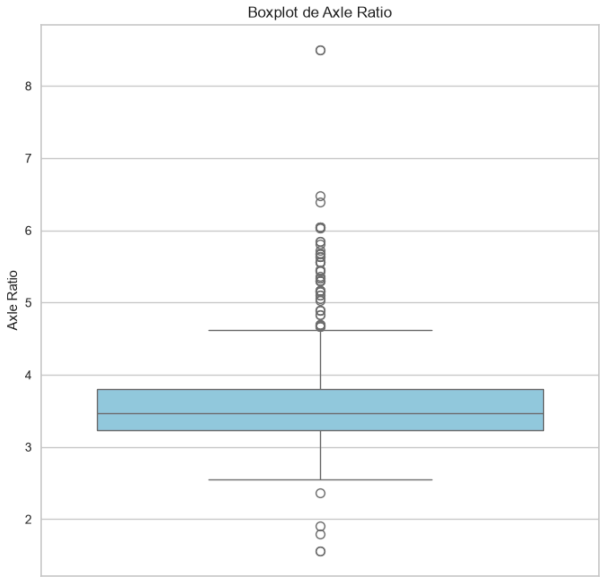


Gráfico 1: Boxplot de Axle Ratio

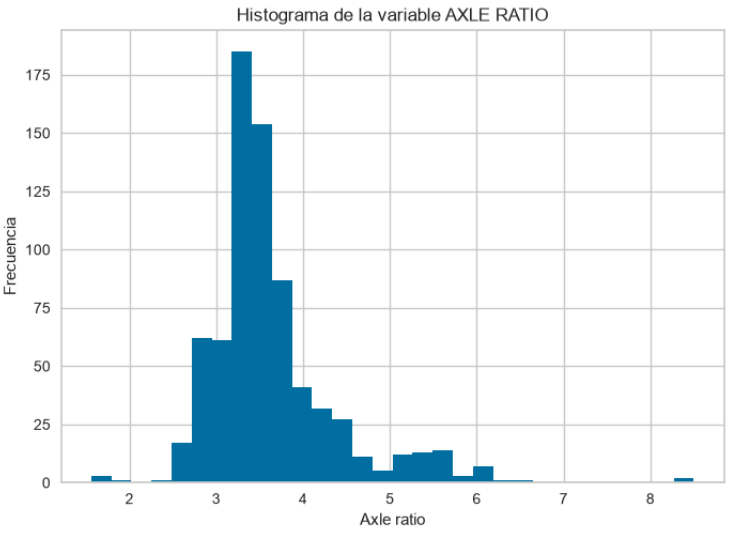


Gráfico 2 : Histograma de Axle Ratio

3.4.3. Resultados obtenidos y discusión

Para poder comprobar o refutar la hipótesis planteada se decidió hacer un test. La primera opción fue un test t, para el cual se debía comprobar el supuesto de normalidad, al hacerlo, tanto por qq plot (gráfico 3) como por un test de shapiro-wilk (`Estadístico = 0.845, p-valor=0.000`) se pudo comprobar que la variable no tiene una distribución normal, por lo que quedó descartado el test t y se realizó un test de Wilcoxon. Los resultados de este fueron los siguientes: Mediana muestral: 3.45; Estadístico: 3218221.5; P-valor: 1.0; En base a estos resultados no se rechaza H0, es decir, no hay evidencia suficiente para afirmar que la mediana de Axle Ratio es mayor a 3.73.

También se decidió hacer un analisis pequeño de la media y las proporciones de autos que superan a 3.73 (Gráfico 4) , en el cual nos podemos encontrar que dos terceras partes del total de vehículos a combustión tienen un axle ratio menor a 3.73, lo cual constata con los resultados de la hipótesis y el test.

Hay suficiente evidencia estadística, entonces, para asegurar que los autos a combustión testeados por EPA en 2025 no tienen un Axle Ratio que se considera alto.

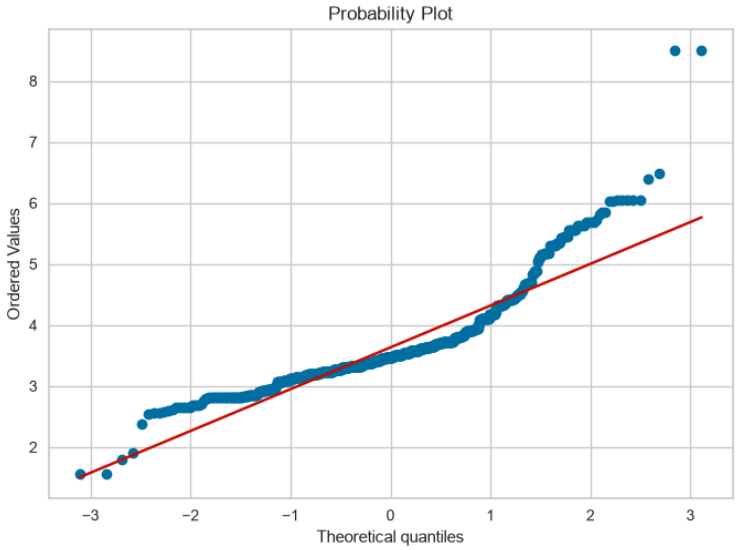


Gráfico 3: QQ-plot de Axle Ratio

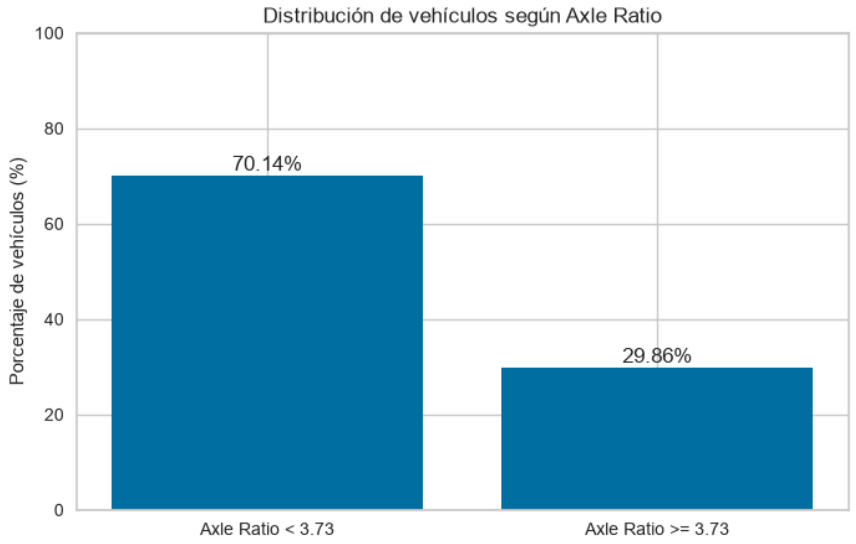


Gráfico 4: Promedio de autos con axle ratio mayores a 3.73

3.5. Hipótesis 2: bivariada propia

3.5.1. “El nivel de emisión de CO2 en autos que utilizan combustión en ciclos urbanos, difiere según el tipo de transmisión utilizado.”

Indagando entre las distintas variables del DataSet hallamos una que identifica el tipo de transmisión que utiliza el vehículo. La transmisión es el conjunto de piezas que lleva la fuerza del motor hasta las ruedas. El motor gira rápido y con poca fuerza; las ruedas necesitan girar más lento y con más fuerza para arrancar o subir una cuesta. La transmisión “traduce” entre ambos mediante marchas dependiendo de lo que precise el auto. Según el tipo de transmisión, el vehículo tiene mayor o menor control sobre cómo se gestionan las marchas. En ciclos urbanos donde constantemente hay arranques, frenadas, velocidades bajas, ralentí y tráfico, la transmisión cambia de marcha o de relación muchísimas veces. Tomando esto, y sabiendo que la emisión de CO2 (que es el principal gas de efecto invernadero) se centra principalmente en ciudades, se nos ocurrió plantear que efecto tiene el tipo de transmisión sobre la emisión de la misma.

¿Por qué sería de utilidad validar esta hipótesis? A nivel regulatorio, permitiría demostrar a organismos como la EPA y el DOT que la emisión de CO2 varía considerablemente según el tipo de transmisión. Esto evidenciaría la necesidad de crear estándares de medición específicos para cada categoría, evitando castigar injustamente a ciertos vehículos por el sistema de transmisión que utilizan. Además, en caso de ser cierta, invitaria a investigar qué tipo de transmisión reduce la emisión de CO2, con el objetivo de incentivar la compra y producción de vehículos que lo implementen.

En el ámbito empresarial, ayudaría a las compañías que adquieren grandes flotas de vehículos de trabajo a elegir la transmisión más conveniente buscando reducir sus emisiones. De esta manera, las empresas podrían evitar posibles multas por contaminación y fortalecer su imagen ecológica frente al público.

3.5.2. Estrategia de abordaje

Como primer acercamiento a poder realizar el test de hipótesis se empezó analizando y limpiando el DataSet y las variables involucradas en el testeo y análisis de la misma. Primero se hizo una limpieza de todas aquellas filas que no correspondiesen a autos puramente de combustión, es decir, eléctricos e híbridos que utilicen Hidrógeno.

Luego se continuó analizando cada variable por separado. Se empezó por la variable de CO2, analizando sus medidas de resumen utilizando describe() y buscando la existencia de NaN's o 0's. En el caso de estos últimos, se identificaron 131 filas donde CO2 contaba con alguno de estos dos valores. En el caso donde el procedimiento utilizado fue Cold CO, el valor de CO2 fue marcado como 0.0 ya que este procedimiento está diseñado específicamente para medir los niveles de Monóxido de arbono (CO) durante el arranque en frío a bajas temperaturas (típicamente 20°F). De esta manera lo más probable es que como el test se centraba únicamente en este tipo de gas, se haya rellenado CO2 con 0 en representación de un valor no válido o no medido.

En el otro caso, todos los NaN correspondian a tipos de procedimientos de Charge Depleting, los cuales corresponden a las fases de evaluación de vehículos híbridos enchufables (PHEV). Durante la fase "Charge Depleting", el vehículo se desplaza utilizando exclusivamente la energía de su batería eléctrica hasta que ésta se agota. Aunque el vehículo contiene gasolina en el tanque ("Tier 2 Cert Gasoline"), el motor de combustión interna permanece apagado durante este ciclo, por lo que no genera ninguna emisión de CO2 en el escape para ser medida o registrada. De esta manera se justifica la ausencia de valores en dicha columna.

En cuanto a la información de resumen de CO2 se pudo apreciar como la media era mayor a la mediana (asimetría con cola a derecha), una enorme diferencia presente entre el máximo valor registrado de emisión de CO2 y el quantil 3, un desvío estándar alto en relación a la media, indicando mucha variabilidad entre los registros, y la presencia de outliers, los cuales probablemente causaban todo lo anterior.Para continuar, se decidió analizar los outliers utilizando la regla del rango intercuartílico (1.5* IQR) de Tukey, estableciendo así un límite superior desde el que empezar a considerar a estos. Se hallaron dos grupos bien marcados, uno correspondiente a autos superdeportivos y autos de lujo/alto rendimiento, y otro correspondiente a camionetas y SUV grandes de lujo y todo terrenos.

Dada esta situación, se decidió eliminar estos casos del análisis. La hipótesis planteada busca que se pueda investigar y decidir cuál es la mejor elección de transmisión si se quiere minimizar la emisión de CO2, o poder plantear nuevos criterios de evaluación en niveles de emisión según tipo de transmisión. En busca de que estos resultados sean más representativos, se eliminan casos excepcionales de autos de altísimo consumo (¡que además son muy caros!) y que son alta minoría en las calles en el día a día.

Luego se dejaron sólo aquellos registros asociados a tests que involucran ciclos urbanos, con el objetivo nuevamente de dar unos resultados que se asocian al uso más cotidiano para todos los vehículos, y más teniendo en cuenta que el control de emisión de gases es mayor y más perjudicial en áreas urbanas.

Por último, para poder garantizar independencia entre las observaciones se decidió agrupar por Veh Mfr Code, Test Vehicle ID y Test Veh Configuration, colapsando los valores

de emisión de CO2, en caso de haber varios, a un único por vehículo utilizando la mediana entre todos estos.

Arrancando a trabajar con la hipótesis en sí, primero se graficaron Notched BoxPlots para observar cómo se distribuían las emisiones de CO2 por tipo de transmisión.

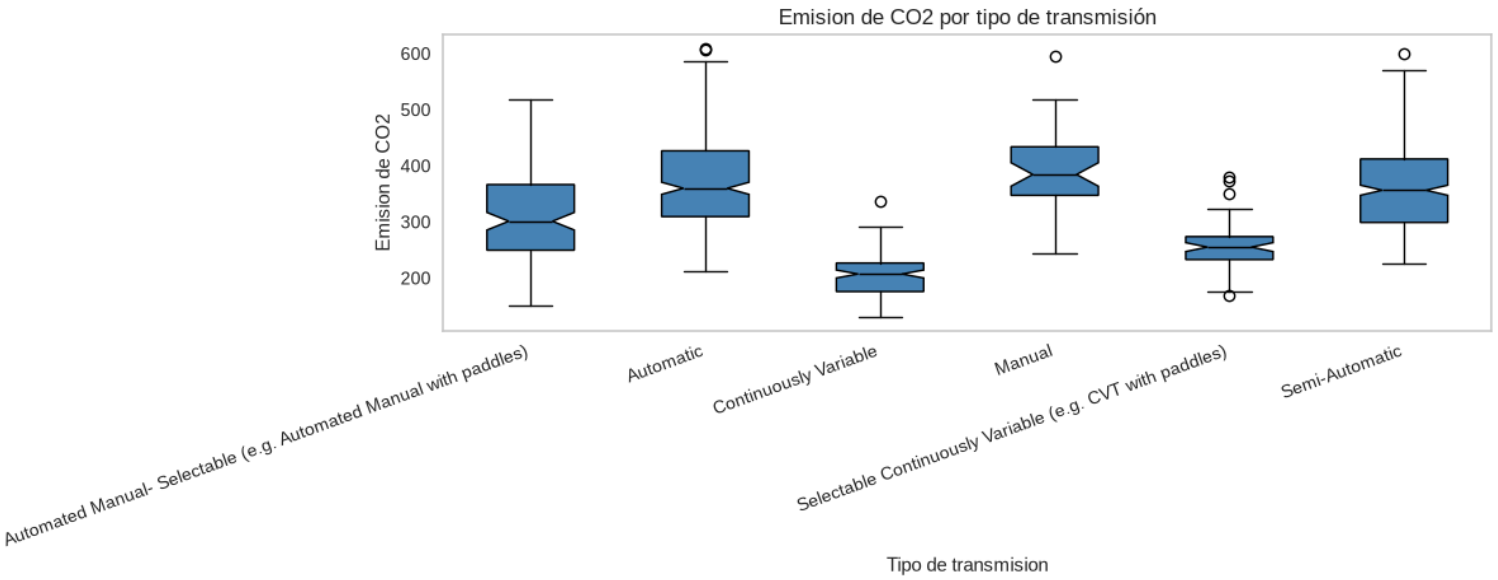


Gráfico 5 :*BoxPlot: emisiones de CO2 por tipo de transmisión*

El boxplot nos muestra que las transmisiones Continuously Variable (mediana cercana a 200 g/mi) y Selectable Continuously Variable (cercana a 250 g/mi) tienen las emisiones más bajas y de menor dispersión. Automated Manual- Selectable ocupa una posición intermedia (alrededor de 300 g/mi), mientras que Semi-Automatic, Automatic y Manual presentan los valores más altos (entre 350 y 400 g/mi aproximadamente) y una mayor variabilidad. Se observan además algunos valores atípicos en la parte superior de varias categorías. Así mismo Manual parece tener su rango intercuartílico bastante simétrico respecto a sus bigotes, y su mediana parecería estar bastante centrada.

Las muecas no parecen coincidir entre sí, salvo semi-automatic y automatic que se aproximan mucho. En un principio todo parecía indicar que hay diferencias significativas entre las emisiones de CO2 entre los distintos tipos de transmisiones. Pero hay que probarlo.

Dado que nos aseguramos independencia entre las variables, con más de dos grupos nuestras opciones para llevar a cabo el test de hipótesis fueron Anova o Kruskal-Wallis. Para el primero era necesario cumplir sus supuestos por lo que procedimos a comprobarlos:

-*Normalidad* (Shapiro-Wilks/QQ-plot): Si no se cumple se pasaría directamente a Kruskal-Wallis

-*Homocedasticidad* (Levene)

3.5.3. Resultados obtenidos y discusión

Primero, y antes de evaluar normalidad mediante Shapiro-WIlks, se arrancó realizando QQ-plots sobre cada uno de los tipos de transmisión y sus emisiones de CO2.

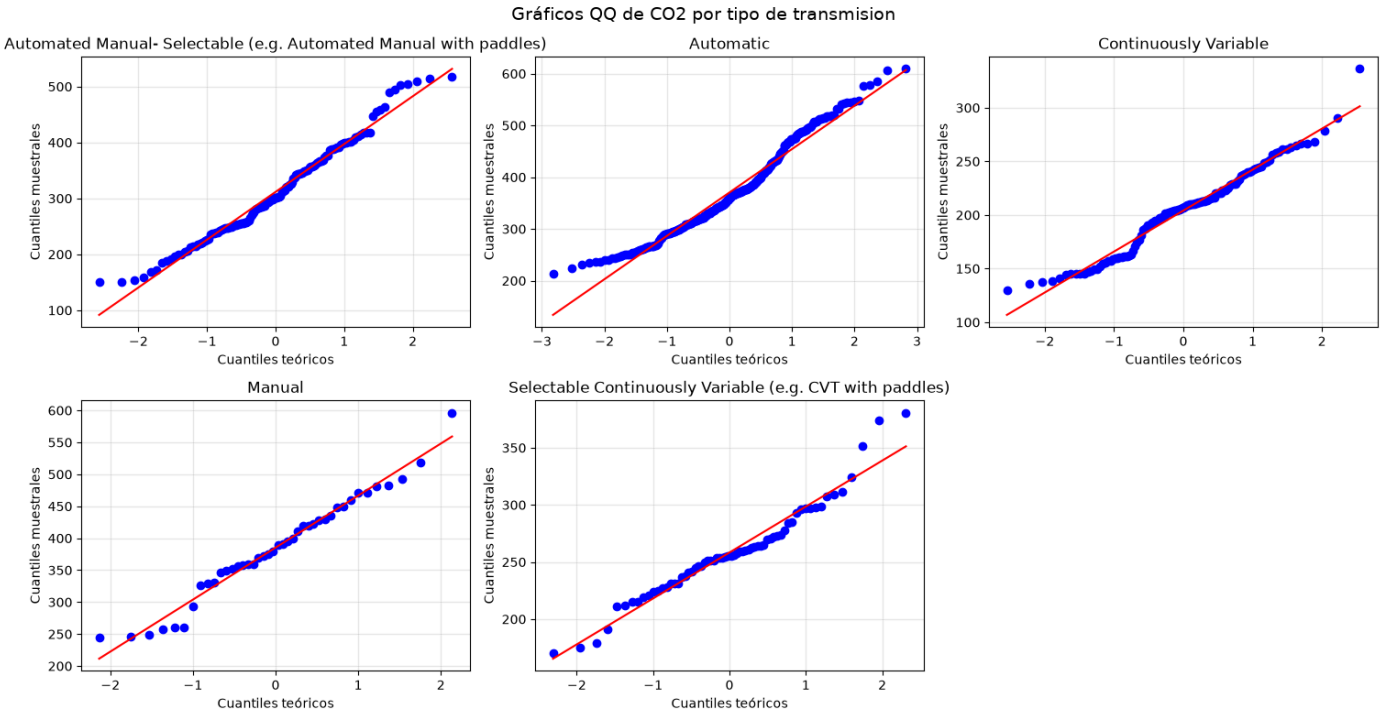


Gráfico 6: *QQ-plots de emisión de CO2 por tipo de transmisión*

Nuevamente Manual parece ajustarse de mejor manera a la recta, recalcar que es la transmisión con menor número de muestras, y de igual manera podemos apreciar como en el resto de transmisiones, la recta parece difuminarse en las puntas, generando curvas o "s".

Tipo de transmisión	Estadístico	P-valor
Manual	0.9731	0.4158
Selectable CVT	0.9576	0.0242
Automated Manual	0.9775	0.02287
Continuously Variable	0.9732	0.01275
Automatic	0.9643	1.333e-06
Semi-automatic	0.9695	3.03e-07

Tabla 1: Resultados de Shapiro-Wilks

Como se puede observar por los p-valores son menores a α= 0.05 en la gran mayoría, estos no se distribuyen normalmente, por lo que se imposibilito poder realizar un test de ANOVA entre las muestras y se tuvo que recurrir a Kruskal-wallis. Remarcar aún así

que los tipos de transmisiones Manuales si se distribuyen normalmente respecto a su emisión de CO2, tal como podíamos sospechar por su boxplot o su QQ-plot.

Finalmente, como no se cumplieron los supuestos necesarios para realizar ANOVA, procederemos a llevar a cabo Kruskal-Wallis.

Statistic = 404.267	**p-valor = 0.000**

Llegamos así a la conclusión que el **p-valor < 0.05 indica** que existe evidencia estadística suficiente para rechazar la hipótesis nula (H0). Esto permite afirmar la hipótesis alternativa (H1). De esta manera se puede afirmar, que efectivamente, existen diferencias en la emisión de CO2 entre los vehículos a combustión en ciclos urbanos. Creemos entonces que es pertinente que los agentes reguladores investiguen qué transmisión reduce la emisión de CO2. En un principio, los boxplots sugieren que estas serían la Continuously Variable y la Selectable Continuously Variable.

3.6. Hipótesis 3 : multivariada propia

3.6.1. *"En vehículos a combustión en ciclo urbano, la potencia del motor determina el perfil multidimensional de emisiones de gases contaminantes (C02, CO, THC, CH4), permitiendo segmentar el impacto ambiental de la flota según su número de cilindros."*

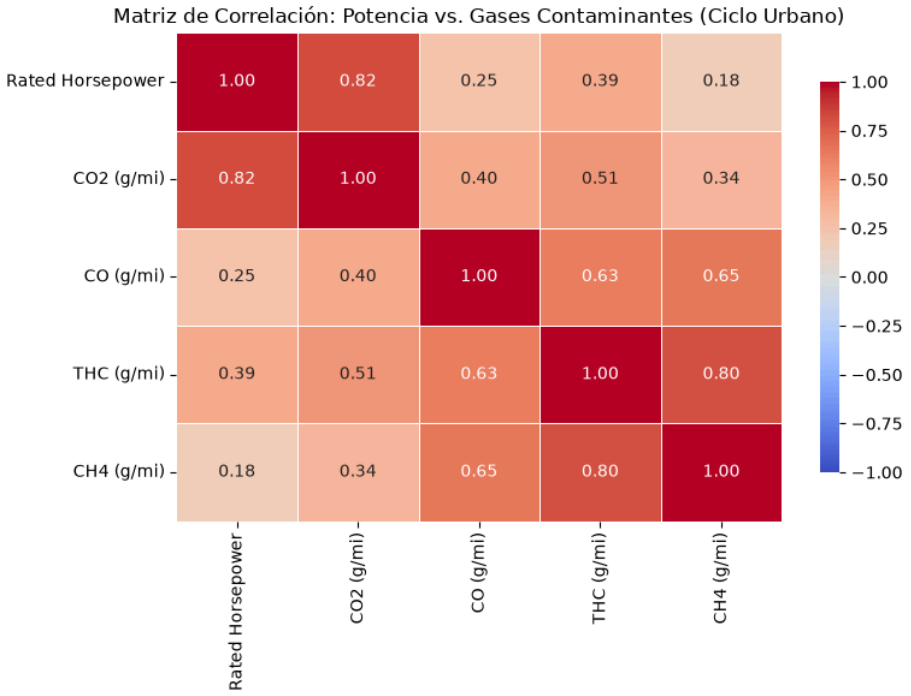
Para las entidades regulatorias ambientales como la EPA evaluar el desempeño ecológico de la flota 2025 solo analizando variables cuantitativas resulta insuficiente. Los motores de combustión interna generan perfiles de emisión complejos donde las caracteristicas interactuan entre si. Comprender cómo se combinan multidimensionalmente la potencia y las emisiones de gases principales (C02, CO, THC, CH4) permite a los fiscalizadores clasificar los vehículos en segmentos de impacto ambiental claros, facilitando la identificación de perfiles mecánicos hiper-contaminantes y orientar las normativas de certificación corporativa.

3.6.2. Estrategia de abordaje
(Seccion 5.3 entrega.ipynb)

Primero comenzamos filtrando el dataset original debido a que la hipótesis plantea un sector especifico. Se aisló la categoría urbana siendo determinada por el tipo de combustible utilizado en esas pruebas específicas en la ciudad(Federal fuel 2-day/3-day exhaust) y se discrimino entre los vehiculos a combustion pura (como diesel y gasolina) para excluir el resto.

En una etapa inicial se consideró incluir otros gases (PM, NOx, N2O), siin embargo, debido a la gran cantidad de valores nulos y a su varianza casi nula en motores de gasolina,

su inclusión agregaba ruido estadístico. Al conservar 5 variables clave (Rated Horsepower, CO2, CO), THC y CH4) logramos capturar la estructura principal de los datos sin perder fidelidad.



Matriz de Correlación / Heatmap

Dado que las variables presentan unidades y escalas distintas (caballos de fuerza vs. gramos por milla), aplicamos StandardScaler para estandarizarlas (media = 0 y desvío estándar = 1). Esto evita que variables con magnitudes grandes dominen artificialmente la varianza del algoritmo.

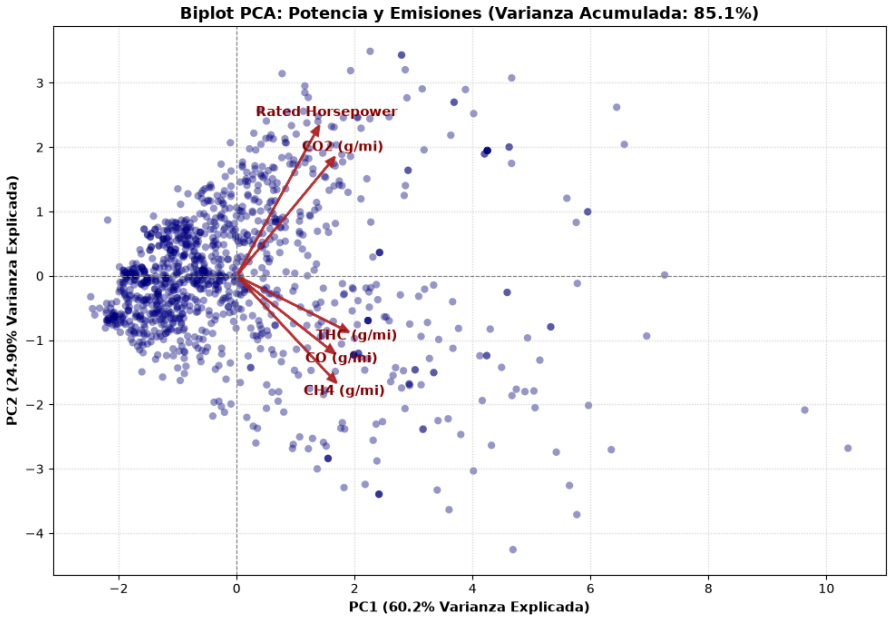


Gráfico 7: Biplot de PCA sin discriminar por "# of CYlinderes and Rotors"

Luego, aplicamos Análisis de Componentes Principales (PCA) para reducir el espacio de 5 dimensiones cuantitativas a 2 componentes principales (PC_1 y PC_2). Se generó también un Biplot superponiendo los vectores de las variables y coloreando las observaciones por la variable discreta de motorización “# of Cylinders and Rotors”.

Finalmente, para aislar y cuantificar el impacto directo de la potencia sobre el gas de mayor volumen /CO2 se ajustó un modelo de Regresión Lineal Simple (OLS) utilizando la librería statsmodels.

3.6.3. Resultados obtenidos y discusión del PCA

El análisis de componentes principales (PCA) mostró que la Componente Principal 1 (PC_1) captura el 61.2% de la varianza total de los datos, mientras que la Componente Principal 2 (PC_2) captura el 23.8% de la varianza total. Por lo tanto la varianza acumulada que se alcanza es de un 85%, reteniendo la mayor parte de la información original. Este porcentaje supera holgadamente el estándar exigido en la teoría para validar representaciones bidimensionales 2D sin pérdida crítica de estructura.

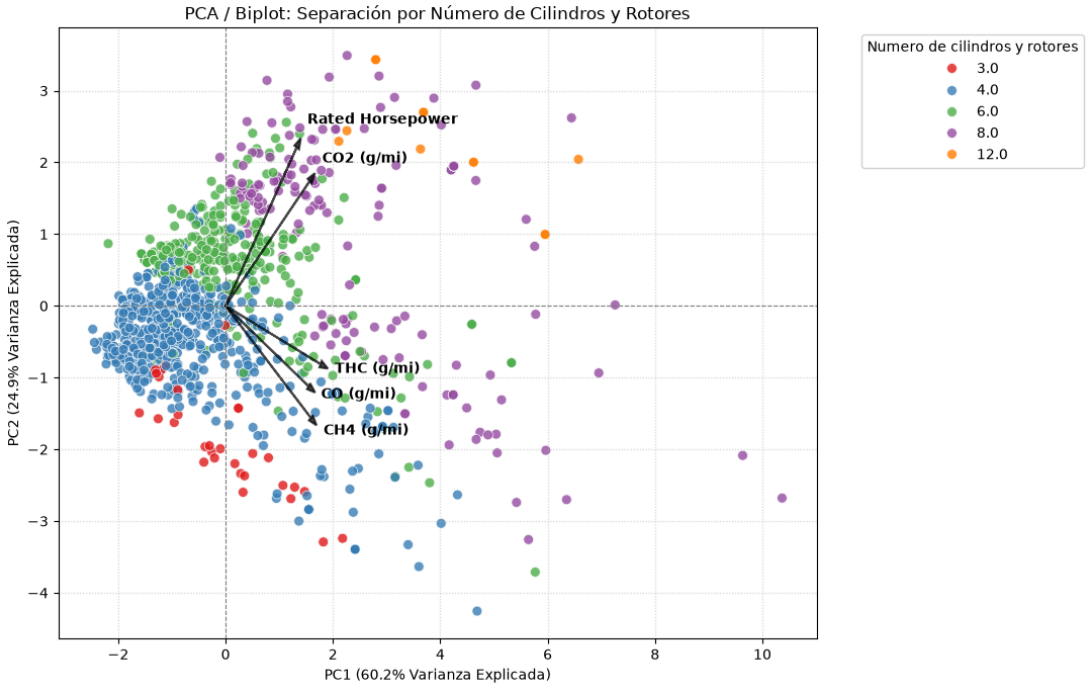


Gráfico 8: Biplot separado según el número de cilindros y rotores

Al analizar el bi-plot se observan los siguientes patrones:

- En PC_1 (Eje de Potencia y Carbono) donde domina la proyección de “Rated Horsepower” y “CO2 (g/mi)”, cuyas flechas apuntan fuertemente en dirección positiva sobre el eje horizontal.

- ➢ En PC_2 (Eje de Hidrocarburos e Ineficiencia) en el que se sintetizan la variación conjunta de THC (g/mi) y CH4 (g/mi), cuyas flechas están alineadas entre sí (confirmando visualmente su alta correlación positiva r > 0.7).
- ➢ Por otro lado, al utilizar segmentación por "# of Cylinders and Rotors" proyectar el número de cilindros sobre el plano PCA, se observa una separación de clusters nítido: los vehículos de 4 cilindros se concentran a la izquierda (baja potencia y menores emisiones), los de 6 cilindros ocupan la región central, y las motorizaciones V8/V12 se posicionan en el extremo derecho.

3.6.4. Resultados obtenidos y discusión de la Regresión lineal

Para cuantificar el impacto directo de la potencia sobre las emisiones de dióxido de carbono, se ajustó un modelo de Regresión Lineal Simple (OLS):

OLS Regression Results

Dep. Variable:	CO2 (g/mi)	R-squared:	0.677
Model:	OLS	Adj. R-squared:	0.676
Method:	Least Squares	F-statistic:	2358.
Date:	Sat, 07 Nov 2026	Prob (F-statistic):	2.04e-278
Time:	12:45:29	Log-Likelihood:	-6171.0
No. Observations:	1128	AIC:	1.235e+04
Df Residuals:	1126	BIC:	1.236e+04
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	154.6840	4.253	36.368	0.000	146.339	163.029
Rated Horsepower	0.5877	0.012	48.556	0.000	0.564	0.611

Omnibus:	110.559	Durbin-Watson:	1.045
Prob(Omnibus):	0.000	Jarque-Bera (JB):	349.584
Skew:	0.470	Prob(JB):	1.23e-76
Kurtosis:	5.560	Cond. No.	872.

Tabla 2 : Tabla de Resultados OLS

- ❖ Coeficiente de Determinación (**R^2**) **= 0.677** (con 67.7% de varianza explicada)
  Esto demuestra que aproximadamente dos terceras partes de la variabilidad total en las emisiones de dióxido de carbono (CO2) en ciclo urbano son explicadas de manera directa por la potencia del motor ("Rated Horsepower").

- ❖ **Estadístico F** (Significancia global) **F = 380.4, p < 0.001**
- ❖ **Pendiente (beta_1) = 0.5877 g/mi por HP (p < 0.001)**
  Existe una relación lineal positiva bien definida. Cada caballo de fuerza adicional ("*Horsepower*") incrementa la emisión promedio de CO2 en 0.5877 g/mi (p < 0.001), reflejando el impacto ambiental directo de motorizaciones más potentes.

- **Ordenada al origen (beta_0) = 154.68 g/mi**
  Se establece en 154.68 g/mi, indicando el nivel base estimado para los vehículos analizados.

La significancia global del modelo es robusta y confirma estadísticamente que la potencia es un predictor clave para estimar la huella de carbono de los vehículos.

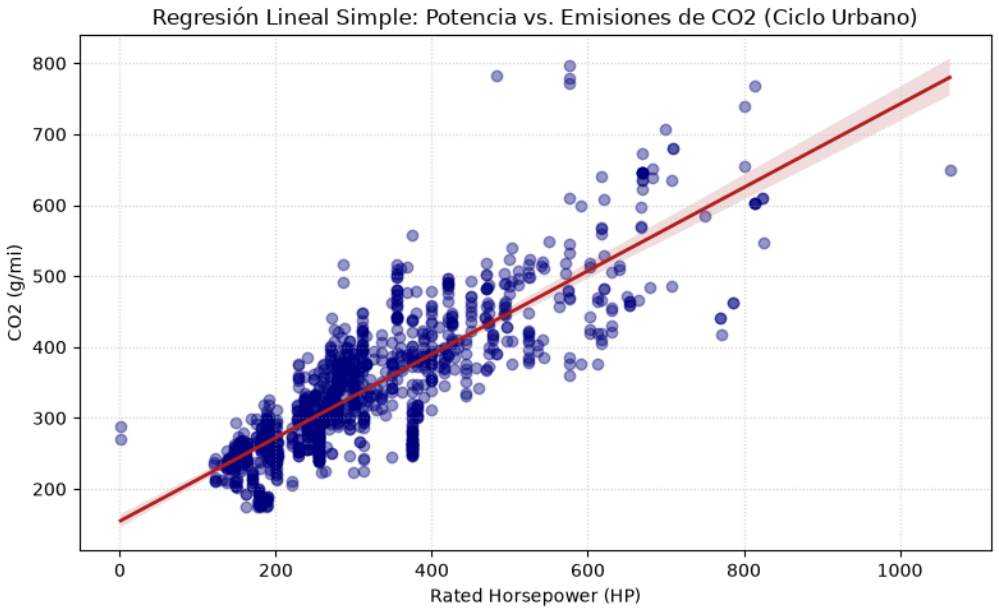


Gráfico 9: Regresión lineal simple; potencia vs emisiones de co2 (urbano)

El análisis de los residuos del modelo permitió evaluar el cumplimiento de las condiciones teóricas del análisis de regresión:

- Homocedasticidad

Al auditar el gráfico de residuos frente a los valores predichos, los errores se distribuyen mayoritariamente en un formato de banda horizontal alrededor del cero; no obstante, se advierte una mayor dispersión y un leve patrón de heteroscedasticidad en el extremo superior, asociado a vehículos de alta gama y altas prestaciones.

- Normalidad

Las pruebas estadísticas formales de Omnibus y Jarque-Bera arrojan p-valores extremadamente bajos Prob(Omnibus) = 0.000 y Prob(JB) = 1.23*10^-76, ambos por debajo del umbral alfa = 0.05. Esto nos lleva a rechazar la hipótesis de normalidad de los residuos.

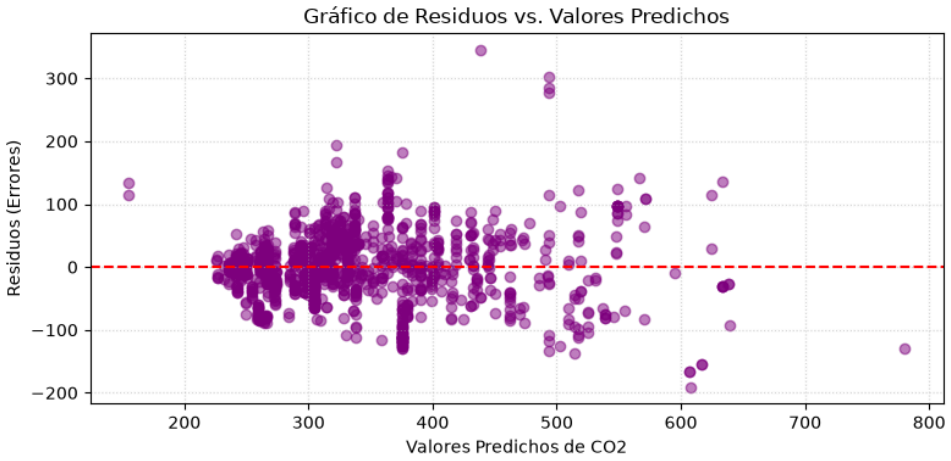


Gráfico 10: Residuos vs valores predichos

3.6.5 Consideraciones Finales

Si bien el modelo lineal simple captura con éxito la tendencia general y ofrece un alto poder explicativo, el incumplimiento del supuesto de normalidad y la leve heteroscedasticidad en vehículos de alta gama que salen del patron, sugieren que la relación subyacente posee componentes no lineales.

Para futuros trabajos, se puede evaluar la implementación de transformaciones sobre la variable respuesta (como log(CO2)) o la incorporación de términos cuadráticos y modelos multivariados que optimicen la precisión predictiva y el cumplimiento de los supuestos estadísticos.

4. Conclusiones

A través de todo el informe estuvimos analizando y estudiando *como las características técnicas de los vehículos influyen en su consumo y emisión de gases.* Las seis hipótesis, tanto las propias como las de la cátedra, apuntan en la misma dirección: el tamaño y la potencia del motor, junto con el tipo de transmisión y de tracción, influyen significativamente tanto en la economía del combustible como en el desempeño ambiental del vehículo.

4.1 Perfil general

Pudimos comprobar por la primera hipótesis univariada propuesta por el grupo que el conjunto de autos testeados no tienen lo que se considera un Axle Ratio alto, esto sugiere que gran parte de la flota está orientada a la eficiencia en ruta más que a la fuerza de empuje. Sobre la economía urbana, la mediana de MPG (26,8) superó el umbral de 25 y el

test de Wilcoxon rechazó H0, por lo que la mayoría de las configuraciones a combustión alcanza al menos 25 MPG en ciclo urbano.

4.2 Transmisión y tracción.

Las diferencias entre grupos fueron estadísticamente significativas en todos los casos. Las emisiones de CO2 urbanas difieren según la transmisión (Kruskal-Wallis = 404,27; $p < 0,001$). Las CVT tienen las emisiones más bajas, y las automáticas, semiautomáticas y manuales las más altas. La economía de combustible también difiere según la tracción en los tres ciclos (HWY, FTP y US06; $p < 0,001$). La tracción delantera es la más eficiente, y la trasera, la 4x4 y la integral rinden de forma parecida entre sí y peor. Esto coincide con el marco teórico: la tracción delantera es más liviana y pierde menos energía, y la CVT mantiene el motor en su régimen óptimo.

4.3 Potencia, emisiones y eficiencia.

El PCA sobre emisiones y potencia retuvo el 85 % de la varianza en dos componentes. Potencia y CO2 dominan el primer eje, y los hidrocarburos (THC y CH4) el segundo. Los vehículos se separan por número de cilindros, con los de 4 cilindros en la zona de baja potencia y bajas emisiones y los V8/V12 en el extremo opuesto. La regresión simple indica que cada caballo de fuerza adicional se asocia con 0,59 g/mi más de CO2.

El análisis multivariado de eficiencia urbana reforzó este resultado. El PCA (92,2 % de varianza acumulada) resumió potencia, cilindrada y cilindros en un único eje de “tamaño de motor”, a lo largo del cual el MPG cae de forma clara. El T-SNE y el K-Means ($k = 3$) recuperaron tres perfiles: vehículos livianos y eficientes (el grupo mayoritario, con predominio de tracción delantera y CVT), intermedios, y pesados o de alto rendimiento (el grupo más pequeño y menos eficiente).

Para la **EPA** y el **DOT**, los resultados respaldan la necesidad de considerar la categoría de transmisión y tracción al comparar vehículos y fijar estándares, para no penalizar injustamente a ciertas configuraciones. Para una empresa que compre flotas, la combinación que minimiza emisiones y consumo es: motor pequeño, tracción delantera y CVT. Como también se destacó en la introducción, conocer bien el dominio mecánico fue clave para detectar errores de datos, decidir qué casos excluir e interpretar los resultados.

Referencias

Fuentes Oficiales y Datos del Dominio (EPA / Gobierno de EE. UU.)

U.S. Environmental Protection Agency (EPA. (2026).

- EPA Fuel Economy Data - Model Year 2025 Test Car List (Dataset "25-testcar-2026-01-21.xlsx").
- Office of Transportation and Air Quality.

  https://www.epa.gov/compliance-and-fuel-economy-data

  https://www.epa.gov/compliance-and-fuel-economy-data/data-cars-used-testing-fuel-economy

- Fuel Economy Label Updates: Overview and Revisions*. https://www.epa.gov/recalls/fuel-economy-label-updates
- Regulations for Onroad Vehicles and Engines
- https://www.epa.gov/regulations-emissions-vehicles-and-engines/regulations-onroad-vehicles-and-engines

U.S. Department of Energy (DOE) & U.S. EPA (2026).

- Fuel Economy Guide and Vehicle Testing Procedures

  https://www.fueleconomy.gov/